

ŽILINSKÁ UNIVERZITA V ŽILINE

**FAKULTA ELEKTROTECHNIKY
A INFORMAČNÝCH TECHNOLOGIÍ**

Katedra multimédií a informačno-komunikačných technológií

28260120262017

**VYUŽITIE HLĚBKOVÝCH MÁP PRI
FOTOGRAOMETRICKEJ REKONŠTRUKCII 3D
OBJEKTŮV**



ŽILINSKÁ UNIVERZITA V ŽILINE
Fakulta elektrotechniky
a informačných technológií

**Katedra multimédií a informačno-komunikačných
technológií**

Využitie hĺbkových máp pri fotogrametrickej rekonštrukcii 3D objektov

DIPLOMOVÁ PRÁCA

Študijný odbor:	informatika
Študijný program:	multimediálne inžinierstvo
Vedúci diplomovej práce:	Štech Adam, Ing. PhD.
Pracovisko vedúceho práce:	Katedra multimédií a informačno-komunikačných technológií, FEIT, Žilinská univerzita v Žiline

Žilina, 2026

Michal Červenec, Bc.



ZADANIE DIPLOMOVEJ PRÁCE

Meno a priezvisko: **Bc. Michal Červenec**
Školiace pracovisko: **KMIKT, FEIT, Žilinská univerzita v Žiline**
Študijný odbor: **informatika**
Študijný program: **multimediálne inžinierstvo**
Akademický rok: **2025/2026**

Názov diplomovej práce: **Využitie hĺbkových máp pri fotogrametrickej
rekonštrukcii 3D objektov**

Pokyny na vypracovanie diplomovej práce:

1. Teoreticky spracujte princípy fotogrametrie, tvorby hĺbkových máp a metód 3D rekonštrukcie.
2. Preskúmajte a navrhните možnosť implementácie generovania hĺbkových máp z obrazových dát.
3. Využite tradičný spôsob generovania hĺbkových máp pomocou metód ako COLMAP, OpenCV a neurónových sietí ako MiDaS, MVSNet.
4. Navrhните skript na spracovanie datasetu a vytvorenie hĺbkových máp.
5. Porovnajte kvalitu a efektivitu jednotlivých metód (čas, presnosť, vizuálna kvalita).
6. Zhodnoťte získané poznatky a definujte výhody a nevýhody použitých metód v rôznych scenároch (interiér, exteriér, jednoduché vs. komplexné objekty).

Jazyk: **slovenský**
Vedúci diplomovej práce: **Štech Adam, Ing. PhD.**
Pracovisko: **Katedra multimédií a informačno-komunikačných technológií,
FEIT, Žilinská univerzita v Žiline**

Dátum odovzdania: **27.04.2026**

prof. Ing. Róbert Hudec, PhD., v.r.
garant študijného programu

prof. Ing. Róbert Hudec, PhD., v.r.
vedúci katedry

ANOTAČNÝ ZÁZNAM

Žilinská univerzita v Žiline

Fakulta elektrotechniky a informačných technológií

Katedra multimédií a informačno-komunikačných technológií

Typ práce:	Diplomová práca
Meno a priezvisko:	Bc. Michal Červenec
Akademický rok:	2025/2026
Názov práce:	Využitie hĺbkových máp pri fotogrametrickej rekonštrukcii 3D objektov
Počet strán:	66
Počet obrázkov:	80
Počet tabuliek:	13
Počet grafov:	0
Počet príloh:	38
Počet použ. lit.:	22

Anotácia v slovenskom jazyku:

Práca sa zaoberá využitím tvorby hĺbkových máp v rámci fotogrametrického postupu. Jej hlavným cieľ je tieto metódy analyzovať a následne s použitím praktickej implementácie porovnať. V práci sa navrhuje pre každú metódu skript na vytvorenie 3D rekonštrukcie objektu. Vytvorené mračná bodov sa porovnávajú z hľadiska presnosti, nárokov na zdroje a vizuálnu kvalitu. Na záver sú formulované výsledky porovnaní, výhody a nevýhody metód, možné využitie a návrh na prípadný ďalší vývoj nadväzujúci na túto prácu.

Annotation in foreign language (english/deutsch):

This thesis deals with usage of creation of depth maps in photogrammetric process. Main goal is to analyze these methods and then compare them with use of practical implementation. In this thesis was for each method designed script to create 3D reconstruction. Created point clouds are compared from the point of precision, resources requirements and visual quality. At the end are results of comparisons, advantages and disadvantages of methods, possible usage and suggestions for next possible development connected to this thesis.

Kľúčové slová: Fotogrametria, hĺbkové mapy, skript, mračná bodov, 3D rekonštrukcia

Vedúci diplomovej práce: Štech Adam, Ing. PhD.

Dátum odovzdania ZP: 27.4.2026

POĎAKOVANIE

Chcel by som sa poďakovať predovšetkým vedúcemu práce Štech Adam, Ing. PhD., za spoluprácu a vedenie počas celej realizácie práce, pomoc pri riešení problémov a ochotu pri komunikácii od výberu práce až po finálne odovzdanie.

Tiež ďakujem, všetkým pedagógom a odborníkom z praxe, ktorý mi počas štúdia napomohli k získaniu vedomostí uplatnených aj v tejto práci.

V neposlednom rade ďakujem všetkým, ktorý mi vytvorili zázemie a podmienky na úspešnú realizáciu a dokončenie práce.

ABSTRAKT

Abstrakt v slovenskom jazyku

Práca sa zameriava na oblasť digitalizácie objektov pomocou fotogrametrie, ktorá využíva na 3D rekonštrukciu objektov pomocou hĺbkových máp. Analyzuje klasické aj modernejšie metódy 3D rekonštrukcie s využitím hĺbkových máp a implementuje automatizované postupy na vykonanie rekonštrukcie zo vstupných snímok. Výsledky jednotlivých metód sa porovnávajú vzhľadom na presnosť voči referenčnému mračnu bodov. Porovnáva sa tiež výkon metód a vizuálna kvalita jednotlivých rekonštrukcií. Práca využíva skriptovací jazyk Python a dávkové súbory na tvorbu nástrojov automatizujúcich proces rekonštrukcie, s využitím dostupných rozhraní jednotlivých metód. Na základe porovnania výsledkov konštatuje stav klasických metód oproti moderným metódam využívajúcim neurónové siete. Práca definuje aj priestor na ďalší vývoj týchto modernejších metód s predpokladom na značné zlepšenie výsledkov.

Kľúčové slová: fotogrametria, hĺbkové mapy, 3D rekonštrukcia, skripty

Abstract in foreign language (english)

The thesis deals with part of photogrammetry, that uses depth maps for 3D reconstruction of objects. It analyzes classical as same as modern methods for 3D reconstruction that use depth maps and implements automated approaches to create reconstructions from datasets. Results of each method are compared based on precision regarding the reference point cloud; it compares power of methods and visual quality of individual reconstructions. Thesis uses scripting language Python and batch files to create tools that automate the process of reconstruction, with use of each method's available interfaces. Based on results of comparisons it points out state of classical methods as opposed to modern methods that use neural networks. The thesis defines space for further development of given modern methods, with presumption of significant possible improvement of results.

Keywords: photogrammetry, depth maps, 3D reconstruction, scripts

OBSAH

Anotačný záznam.....	i
PodĎakovanie	ii
Abstrakt.....	iii
Abstrakt v slovenskom jazyku	iii
Abstract in foreign language (english).....	iii
Obsah	iv
Zoznam obrázkov a tabuliek.....	vii
Zoznam skratiek.....	ix
Úvod.....	1
1 Ciele práce	3
1.1 Hlavný cieľ	3
1.2 Čiastkové ciele	3
2 Rekonštrukcia 3D objektov	4
2.1 Metódy 3D rekonštrukcie	4
2.1.1 Tradičné metódy	4
2.1.2 Moderné prístupy	6
2.1.3 Softvérové nástroje a knižnice	10
2.2 Fotogrametria.....	13
2.2.1 História.....	13
2.2.2 Princípy, geometrické modely a výpočty	14
2.2.3 Využitie fotogrametrie vo vede a praxi	17
2.3 Hĺbkové mapy.....	17
2.3.1 Definícia a princíp tvorby	17
2.3.2 Spôsoby získavania hĺbkových máp	18
2.3.3 Formáty reprezentácie a vizualizácie.....	19
3 Analýza a návrh riešenia.....	21
3.1 Preskúmanie možností generovania hĺbkových máp z obrazových dát	21
3.1.1 Hĺbkové mapy a 3D rekonštrukcia v Colmap.....	21
3.1.2 Hĺbkové mapy a 3D rekonštrukcia s OpenCV a Meshroom	22
3.1.3 Hĺbkové mapy a 3D rekonštrukcia s MiDaS	23
3.1.4 Hĺbkové mapy a 3D rekonštrukcia s MVSNet	24
3.1.5 Hĺbkové mapy a 3D rekonštrukcia s PatchMatchNet.....	25
3.1.6 Výber vhodných datasetov.....	25

3.2	Návrh implementácie	30
3.2.1	Architektúra riešenia	30
3.2.2	Softvérové a hardvérové prostredie	31
4	Praktická časť – implementácia	32
4.1	Generovanie hĺbkových máp tradičnými metódami	32
4.1.1	Implementácia Meshroom	32
4.1.2	Implementácia Colmap	34
4.2	Generovanie hĺbkových máp pomocou neurónových sietí	34
4.2.1	Implementácia neurónovej siete MiDaS	34
4.2.2	Implementácia neurónovej siete PatchmatchNet	36
4.3	Automatizácia spracovania dát	37
4.3.1	Návrh a implementácia skriptu	37
4.4	Ukážky výsledkov	38
4.4.1	Výsledné surové mračná bodov z Colmap	38
4.4.2	Výsledné surové mračná bodov z Meshroom	39
4.4.3	Výsledné surové mračná bodov z PatchmatchNet	40
4.4.4	Výsledné surové mračná bodov z MiDaS	41
4.4.5	Referenčné mračná	42
5	Experimentálne vyhodnotenie	43
5.1	Porovnávacie kritériá	43
5.1.1	Presnosť	43
5.1.2	Zdroje	44
5.1.3	Vizuálna kvalita rekonštrukcie	44
5.2	Porovnanie výsledkov metód	45
5.2.1	Porovnanie pre dataset 1	45
5.2.2	Porovnanie pre dataset 2	47
5.2.3	Porovnanie pre dataset 3	48
5.2.4	Porovnanie pre dataset 4	51
5.2.5	Porovnanie pre dataset 5	52
5.2.6	Porovnanie s MiDaS	53
5.2.7	Súhrnné porovnanie	56
5.2.8	Porovnanie zaťaženia zdrojov	59
5.2.9	Vizuálne hodnotenie výsledkov	60
5.3	Diskusia	63
5.3.1	Interpretácia výsledkov	63

Záver	65
Zoznam použitej literatúry	1
Zoznam použitých promptov	3
Čestné vyhlásenie	4
Prílohová časť	5
Zoznam príloh.....	I
Príloha A Výsledné mračná z jednotlivých metód 3D rekonštrukcie	II
Príloha B Porovnania mračien Z jednotlivých Metód 3D rekonštrukcie voči referenčnému mračnu	X
Príloha C Porovnania výkonu a zaťaženia zdrojov	XVI
Príloha D Vizúálne zhodnotenie kvality pre jednotlivé datasety	XVIII
Príloha E Link na repozitár s výsledkami práce	XXI

ZOZNAM OBRÁZKOV A TABULIEK

Obrázok 2.1 Riedke (a) a husté (b) mračno bodov, zdroj: [5]	6
Obrázok 2.2 Postup 3D rekonštrukcie s voxelovým prístupom, zdroj: [6]	8
Obrázok 2.3 Radiačné neurónové polia, zdroj: [8]	9
Obrázok 2.4 Optimálny postup pre 3D Gaussian splatting, zdroj: [10]	9
Obrázok 2.5 GUI programu COLMAP s rekonštruovaným objektom, zdroj: [12].....	10
Obrázok 2.6 Kvalitatívne výsledky testu siete MiDaS, zdroj: [14]	11
Obrázok 2.7 Postupnosť krokov pri MVSNet, zdroj: [5]	12
Obrázok 2.8 Epipolárna geometria, zdroj: [17]	15
Obrázok 2.9 Vonkajšie a vnútorné parametre kamery, zdroj: [18]	16
Obrázok 2.10 Parametre pre výpočet disparity, zdroj: [19].....	18
Obrázok 2.11 Ukážka hĺbkovej mapy vytvorenej pomocou neurónovej siete MiDaS uložená ako PNG súbor	19
Obrázok 3.1 Socha vo vedeckom parku UNIZA	27
Obrázok 3.2 Gerrard Hall, zdroj: [20]	27
Obrázok 3.3 Model lebky, zdroj: [21]	28
Obrázok 3.4 Ulita, zdroj: [22].....	29
Obrázok 3.5 Trs banánov, zdroj: [22].....	29
Obrázok 3.6 Bloková schéma 3D rekonštrukcie	30
Obrázok 4.1 Sekvencia rekonštrukcie Meshroom, 1. časť	32
Obrázok 4.2 Sekvencia rekonštrukcie Meshroom, 2. časť	33
Obrázok 4.3 Sekvencia rekonštrukcie Meshroom, 3. časť	33
Obrázok 4.4 Mračno z jednej fotografie vytvorené pomocou MiDaS.....	35
Obrázok 4.5 Mračno vyskladané z celého datasetu cez MiDaS	35
Obrázok 4.6 Neúspešné výsledky rôznych iterácií skriptu pre MiDaS	36
Obrázok 4.7 Dropdown na výber datasetu a GPU	38
Obrázok 4.8 Zaškrŕavacie možnosti metód rekonštrukcie a tlačidlá na ovládanie aplikácie	38
Obrázok 4.9 Sekcia pre výpis výsledkov a logu	38
Obrázok 4.10 Mračno z Colmap - dataset socha	39
Obrázok 4.11 Mračno z Meshroom - dataset lebka	40
Obrázok 4.12 Mračno z PatchmatchNet - dataset trs banánov	41
Obrázok 4.13 Mračno z jedného obrázka z MiDaS - dataset ulita	42
Obrázok 5.1 Graf hodnôt vzdialenosti bodov Colmap, dataset socha, na osi X hodnoty vzdialenosti od 0 do 1, na osi Y počty bodov rádovo v 10^5	46
Obrázok 5.2 Graf hodnôt vzdialenosti bodov Meshroom, dataset socha, na osi X hodnoty vzdialenosti od 0 do 1, na osi Y počty bodov rádovo v 10^5	46
Obrázok 5.3 Graf hodnôt vzdialenosti bodov MVSNet, dataset socha, na osi X hodnoty vzdialenosti od 0 do 1, na osi Y počty bodov rádovo v 10^5	47
Obrázok 5.4 Dve mračná (zvýraznené žltou a červenou farbou) pred ICP	47
Obrázok 5.5 Nesprávne zarovnané mračná po ICP	48
Obrázok 5.6 Graf hodnôt vzdialenosti bodov Colmap, dataset lebka	50
Obrázok 5.7 Graf hodnôt vzdialenosti bodov Meshroom, dataset lebka	50
Obrázok 5.8 Graf hodnôt vzdialenosti bodov MVSNet, dataset lebka.....	51
Obrázok 5.9 Heat mapa porovnania neúplného mračna s referenčným	53

Obrázok 5.10 Zarovnanie pomocou 4 párov bodov	54
Obrázok 5.11 Pred zarovnaním cez algoritmus ICP.....	54
Obrázok 5.12 Poloha mračien po zarovnaní algoritmom ICP	55
Obrázok 5.13 Výsledok porovnania	55
Obrázok 5.14 Trendová krivka pre strednú vzdialenosť	57
Obrázok 5.15 Trendová krivka pre štandardnú odchýlku.....	57
Obrázok 5.16 Trendová krivka pre sigmu	58
Obrázok 5.17 Trendová krivka pre maximálnu vzdialenosť	58
Obrázok 5.18 Trendová krivka pre maximálnu chybu	59
Obrázok 5.19 Vlastnosti rekonštruovaného objektu, dataset socha.....	61
Tabuľka 4.1 Počty bodov v mračnách z Colmap.....	39
Tabuľka 4.2 Počty bodov v mračnách z Meshroom	40
Tabuľka 4.3 Počty bodov v mračnách z PatchmatchNet	41
Tabuľka 5.1 Výsledky porovnania metód pre dataset socha	46
Tabuľka 5.2 Výsledky porovnania metód pre dataset lebka.....	49
Tabuľka 5.4 Spotreba zdrojov pri rekonštrukcii, dataset socha.....	60

ZOZNAM SKRATIEK

Skratka	Anglický význam	Slovenský význam
SfM	Structure-from-Motion	
MVS	Multi-view stereo	viacpohľadové stereo
NeRF	neural radiance field	neurónové polia jasů
MiDaS	Mixed Data Sampling	vzorkovanie zmiešaných dát
BSD	Berkeley Software Distribution	
CAD	Computer-Aided Design	projektovanie počítačom
CPU	Central Processing Unit	centrálne procesorová jednotka
ToF	Time of Flight	čas letu
GUI	Graphical User Interface	grafické používateľské rozhranie
RANSAC	Rabdom Sample Consensus	zhoda náhodných vzoriek
CUDA	Compute Unified Device Architecture	jednotná výpočtová architektúra zariadení
GPU	Graphics Processing Unit	grafický procesor
DPT	Dense Prediction Transformer	transformátor pre hustú predikciu
PLY	Polygon File Format	formát súboru polygónov
JPEG	Joint Photographic Experts Group	Jednotná skupina expertov na fotografiu
PNG	Portable Network Graphics	prenosná sieťová grafika
TIFF	Tag Image File Format	formát označenia obrazových súborov
ICP	Iterative Closest Point	iteratívny algoritmus najbližších bodov

ÚVOD

Žijeme v dobe jednotiek a núl, preto je trendom uplynulých rokov všetko digitalizovať. Uľahčuje nám to archiváciu, spracovanie aj distribúciu pre ďalšie spracovanie. Obzvlášť kľúčovou je digitalizácia objektov reálneho sveta do 3D digitálnych modelov v pokiaľ možno čo najvernejšom prevedení, vizualizácií. S napredujúcim technologickým rozvojom tvoríme stále nové metódy, ktoré sú schopné efektívne a presne transformovať fyzické objekty na jednotky a nuly. Jednou vedeckou disciplínou, ktorá sa zaoberá rekonštrukciou je fotogrametria. Fotogrametria zoskupuje množinu metód, ktoré využívajú fotografie objektov na tvorbu digitálnej reprezentácie objektov. V súčasnosti predstavuje veľmi dostupné riešenia vďaka faktu, že prakticky každý dnes vlastní mobilný telefón s fotoaparátom a na realizáciu fotogrametrie takéto bežne fotografie postačujú. Existujú klasické postupy a algoritmy realizujúce 3D rekonštrukciu avšak moderná fotogrametria využíva aj metódy založené na neurónových sieťach a hlbokom učení, ktoré je nesmierne populárne a zažíva obrovský rozmach a rozvoj. Jedným z najpopulárnejších postupov v týchto metódach je využitie hĺbkových máp na zefektívnenie algoritmov 3D rekonštrukcie. Hĺbkové mapy ako jednoduchá reprezentácia hĺbky - vzdialenosti objektov od snímacieho zariadenia, umožňujú pomerne rýchlu rekonštrukciu a takéto mapy nie sú náročné na skonštruovanie. Existujú viaceré spôsoby ich výpočtu a jednotlivé metódy implementujú ich použitie rôznym spôsobom. V našej práci sa pozrieme práve na metódy, realizujúce 3D rekonštrukciu s využitím hĺbkových máp. Preveríme ako sú na tom klasické metódy postavené na algoritimizácii oproti moderným metódam využívajúcim neurónové siete, či sú ešte stále schopné konkurovať a dosahovať dobré výsledky alebo sa stávajú zastaralými. Pozrieme sa na stav nastupujúcich technológií a zistíme či sú vhodné na použitie alebo stále vyžadujú čas a vývoj na dosiahnutie maximálneho potenciálu. Pre jednotlivé metódy zostavíme postup rekonštrukcie do 3D mračna zo vstupných fotografií, vo forme skriptu, ktorý automatizovane a univerzálne vykoná celý proces. Výsledky týchto rekonštrukcií získame z datasetov s rôznymi vlastnosťami aby sme mohli porovnať nielen metódy medzi sebou, ale aj ich vlastnosti pri práci s rôznymi typmi rekonštruovaných scén. Tieto výstupné mračná porovnáme voči referenčnému mračnu aby sme mohli analyzovať ich presnosť. Počas všetkých rekonštrukcií budeme monitorovať ako bol zaťažovaný hardvér na ktorom prebiehajú aby sme následne vykonali porovnanie ich výkonu a požiadavky na

dostupné zdroje. V neposlednom rade sa pozrieme na vizuálnu kvalitu výsledných 3D rekonštrukcií a zhodnotíme ju s ohľadom na typ rekonštruovanej scény. V závere zhodnotíme ako boli naplnené naše očakávania a predpoklady, pokúsime sa priblížiť náš pohľad na stav jednotlivých metód, ich využitie a priestor na ďalší vývoj.

Motiváciou pri tvorbe tejto práce pre nás bol pravidelný kontakt s technológiou 3D tlače, ktorá dokáže v spojení s metódami 3D rekonštrukcie dosiahnuť zaujímavé výsledky a má potenciál pre akademické, priemyselné ale aj osobné využitie. Možnosť zvoliť metódu rekonštrukcie, ktorá pre špecifické podmienky dosiahne dobré výsledky je pre využiteľnosť vytvorených rekonštrukcií podstatným zlepšením. Predstavuje to potenciálne zefektívnenie mnohých procesov a otvára dvere pre masové využitie vďaka jednoduchej dostupnosti týchto metód. Automatizácia zas umožňuje skrátenie času na osvojenie si postupov a približuje technológiu aj používateľom bez hlbších znalostí problematiky.

1 CIELE PRÁCE

V prvej kapitole popisujeme hlavný cieľ o čom bude daná práca pojednávať a stanovené čiastkové ciele na splnenie stanovených požiadaviek v práci.

1.1 Hlavný cieľ

Trend digitalizácie vytvára potrebu efektívne spracovať a rekonštruovať objekty reálneho sveta do kvalitných 3D digitálnych objektov.

Hlavným cieľom tejto práce je analyzovať možnosti 3D rekonštrukcie pomocou fotogrametrie s použitím hĺbkových máp. Vytvoriť postup tvorby hĺbkových máp pomocou tradičnejších aj moderných technológií. Následne navrhnúť a spracovať skript na automatizované spracovanie dátových kolekcií a na záver otestovať a porovnať výsledky jednotlivých metód.

1.2 Čiastkové ciele

Na dosiahnutie hlavného cieľa je predpokladom splnenie nasledovných čiastkových cieľov:

1. Naštudovanie teórie tvorby hĺbkových máp, fotogrametrie a metód 3D rekonštrukcie z odbornej literatúry a vedeckých databáz.
2. S využitím nadobudnutých poznatkov navrhnúť možnú implementáciu generovania hĺbkových máp pomocou tradičných metód, ako COLMAP a OpenCV, ale aj pomocou moderných neurónových sietí MiDaS a MVSNet.
3. Návrh skriptu, ktorého úlohou bude spracovať dataset a použiť ho na vytvorenie hĺbkových máp pomocou jednotlivých definovaných metód.
4. Porovnanie výsledkov jednotlivých metód z hľadiska kvality a efektivity, predovšetkým doba trvania, presnosť rekonštrukcie a vizuálna kvalita výsledného digitalizovaného objektu.

2 REKONŠTRUKCIA 3D OBJEKTOV

Táto kapitola predkladá teoretické základy potrebné pre realizáciu tejto práce a rozoberá jednotlivé problematiky na základe vedeckých poznatkov a výskumov. Je odrazovým mostíkom k úspešnej realizácii praktickej časti práce a zaoberá sa fotogrametriou a jej esenciálnymi súčasťami, rozoberá hĺbkové mapy a ich využitie a približuje jednotlivé metódy prakticky použité v tejto práci.

2.1 Metódy 3D rekonštrukcie

Metódy 3D rekonštrukcie môžeme rozdeliť do dvoch kategórií - klasické metódy, ktoré využívajú predovšetkým algoritmizáciu a matematické výpočty a moderné metódy postavené na neurónových sieťach a hlbokom učení. Obe kategórie majú svoje špecifiká o ktorých hovoria nasledujúce podkapitoly.

2.1.1 Tradičné metódy

Prvou z tradičných metód používaných na 3D rekonštrukciu je Structure-from-Motion (ďalej len SfM). Ide o postup, pri ktorom sa odhaduje štruktúra 3D scény vo forme riedkeho mračna bodov. Zároveň môže prebiehať výpočet parametrov kamier, definované ako vnútorné a vonkajšie parametre (bližšie popísané v nasledujúcich kapitolách). Tieto výpočty sa dejú na základe datasetu pozostávajúceho z množiny 2D obrázkov zachytávajúcich rekonštruovanú scénu. Samotný výpočet môže prebiehať mnohými spôsobmi, pričom záleží od vstupných parametrov a spôsobu ako vznikol dataset, ktorý sa vo výpočte použije. Typicky sú dôležité predovšetkým údaje o tom, v akom poradí sú jednotlivé obrázky a počet kamier, ktoré scénu snímali. SfM algoritmy umožňujú súčasný výpočet projekčných matic a 3D bodov len za použitia bodov, ktoré korešpondujú medzi jednotlivými snímkami [1].

Bez ohľadu na konkrétny algoritmus SfM, je jeho základná štruktúra postupu takmer vždy rovnaká:

1. Detegujeme body v každom zo vstupných obrazov.
2. Vytvoríme páry bodov medzi jednotlivými obrazmi.
3. Vytvoríme 2D spojenia medzi párami bodov.
4. Vytvoríme model z 2D spojení.

5. Pomocou Bundle Adjustment celý model vyladíme.

Z výstupov algoritmov SfM dokážeme následne vytvoriť rovnicu (2.1) na získanie premietacej matice P , ktorá je spoločným základným geometrickým modelom pre SfM aj MSV:

$$P = K [R|t] \quad (2.1)$$

Kde K je matica vnútorných parametrov kamery (vertikálna a horizontálna ohnisková vzdialenosť, hlavné body a zakrivenie). Matica R je matica rotácie kamery a t je posun kamery [2].

A teda pre prepočet medzi x – 2D bodu v snímke a X – 3D bodom v homogénnych súradniciach dostávame:

$$x \approx K [R|t]X \quad (2.2)$$


Už spomenuté výstupy z SfM sa štandardne môžu ďalej využívať v metóde Multi-View Stereo (ďalej len MVS), ktorá pre svoje správne fungovanie predpokladá znalosti o parametroch kamery. Táto metóda vytvára husté mračná bodov z ktorých je následne možné získať veľmi presné 3D modely aj s textúrami. Seitz a kol. zaradujú algoritmy MVS zhruba do štyroch tried:

1. Metódy, kde sa najskôr vypočítava cost funkcia na 3D objeme a následne extrahuje povrch.
2. Metódy, v ktorých iteratívne vyvíjame povrch na minimalizovanie nákladovej funkcie.
3. Obrazovo-priestorové metódy, ktoré počítajú sady hĺbkových máp.
4. Algoritmy, ktoré najskôr extrahujú a spájajú sady bodov a následne prispôbia povrch rekonštruovaným vlastnostiam [3].

Pri algoritmoch MVS neexistuje jedna všeobecná sekvencia krokov, ktoré sa počas algoritmu vykonávajú, nakoľko rôzne prístupy vyžadujú rôzne sekvencie krokov. V rámci tejto práce sa zameriavame predovšetkým na využitie hĺbkových máp a preto sa aj pri MVS viac zameriavame na verzie využívajúce hĺbkové mapy. Goesele a kol. v práci z roku 2006, ktorá sa dá považovať za základ mnohých moderných postupov, postupujú približne po nasledujúcej sekvencii krokov:

1. Vyberie sa referenčný pohľad – pre všetky vstupné obrázky sa rozhodne či je vhodné ako referenčný pohľad.
2. Vyberú sa susedné pohľady – ku každému referenčnému pohľadu sa priradí množina najlepších susedných kamier.
3. Pre každý referenčný pohľad sa vypočíta hĺbková mapa – premietanie pixelov referenčného pohľadu do susedných pohľadov s využitím robustného oknového párovania.
4. Hĺbková mapa sa filtruje a validuje vzhľadom snímkovú konzistenciu.
5. Všetky hĺbkové mapy sa zlúčia do jedného hustého mračna bodov – volumetrické spájanie [4].

Rozdiel výsledného mračna bodov pre obe metódy je možné vidieť nižšie v obrázku Obrázok 2.1. V ľavej časti je riedke mračno bodov, ktoré možno získať aj pomocou SfM, pravá časť zachytáva husté mračno bodov, ktoré je výstupom napríklad aj metódy MVS.



Obrázok 2.1 Riedke (a) a husté (b) mračno bodov, zdroj: [5]

2.1.2 Moderné prístupy

V uplynulej dekáde sme zaznamenali výrazný rozvoj v oblasti vývoja neurónových sietí a hlbokého učenia a ich aplikovania na najrôznejšie problémy, vrátane počítačového

videnia a 3D rekonštrukcie. Tento posun znamenal evolúciu od klasických k vylepšeným a efektívnejším metódam, ktoré riešia nedostatky klasických metód ako sú napríklad:

- Snímková konzistencia je veľmi krehká – dôsledkom sú nepresne hĺbkové mapy plné dier a fragmentov.
- Metódy sa musia meniť podľa typu scény – je nutné optimalizovať algoritmus „ručne“ nie je to riadené dátami, ktoré sa majú spracovať.
- Nevyužívajú sa nijaké štruktúry vyšších úrovní – neexistuje reprezentácia *learned features*.
- Štandardne sa pri MVS kombinujú len informácie z párov a celá scéna sa optimalizuje po tom.

Na rozdiel od klasických metód sa pri Deep learning učí z dát, aká má byť foto-konzistencia. Z dát sa zistí, ktoré pixely sú informatívne, zmeny textúr pri odlišných uhloch, vzhľad povrchu ak sa v obrázkoch nachádza šum, tieň a odlesky, či a kedy sa môže zhodnotenie považovať za spoľahlivé, a toto všetko sa sieť naučí.


Prvým dôležitým posunom vpred pre MSV je využitie metód hlbokého učenia v algoritme. Toto vylepšenie MSV zabezpečuje výrazné zlepšenie snímkovej konzistencie, od explicitného modelovania geometrie sa prechádza k implicitnému. Namiesto hodnotenia každého pixelu len nezávisle sa zameriava na zachytenie vzťahov, prebieha učenie end-to-end čo umožňuje optimalizovať všetky kroky súčasne. Zmenšuje sa veľkosť datasetu potrebného na generovanie, neurónová sieť sa učí aj štatistické rozdelenia a zlepšuje sa tak miera istoty. Algoritmus sa stáva všeobecným a neurónová sieť je schopná sa prispôsobiť scenáru ak sa s nimi pri učení stretla. Metódy MSV, ktoré využívajú hlboké učenie kategorizoval F. Wang a kolektív nasledovne:

- metódy používajúce hĺbkové mapy,
- metódy založené na voxeloch,
- metódy radiačných neurónových polí (ďalej len NeRF),
- metódy založené na 3D Gaussian-Splatting,
- metódy využívajúce kladné spätné väzby [5].

Prvá spomenutá kategória tvorí hĺbkové mapy pomocou 3D konvolúcií a konvolučných neurónových sietí. Má pomerne jednoduchú postupnosť úloh a dobre


funguje aj na menších kolekciami obrázkov. Typickým predstaviteľom tejto kategórie je MVSNet [5].

Metódy, ktoré sa zakladajú na voxeloch rekonštruujú scénu ako 3D voxelovú mriežku s parametrami pre každý voxel. Neurónová sieť potom počíta pravdepodobnosti či voxel patrí do výsledného povrchu ako ukazuje Obrázok 2.2. Metóda dobre počíta hrubšie tvary a vďaka stabilite sa hodí pre robotiku, avšak je obmedzená vysokými pamäťovými nárokmi.




Obrázok 2.2 Postup 3D rekonštrukcie s voxelovým prístupom, zdroj: [6]

Pre metódy NeRF je špeciálne, že reprezentujú scénu, ako funkciu (viď. Obrázok 2.3) a celá scéna je následne ukladaná v parametroch siete nie v klasickom mračne bodov [7]. Tieto metódy majú vysokú kvalitu a sú pomerne detailné. Všeobecne sa dá povedať, že metódy z tejto kategórie sú za poslednú dekádu najväčším posunom a prínosom v oblasti 3D rekonštrukcie a počítačového videnia.



Obrázok 2.3 Radiačné neurónové polia, zdroj: [8]

3D Gaussian splatting je najmladšia zo spomenutých kategórií metód, ktorá namiesto klasických neurónových polí používa množinu 3D Gaussianov. Tie sa optimalizujú gradientovým zostupom, aby zreprodukovali vstupné obrázky (viď. Obrázok 2.4). Tieto metódy majú vyššiu rýchlosť renderingu dokonca aj ako metódy NeRF a dosahujú výbornú vizuálnu kvalitu [9].




Obrázok 2.4 Optimálny postup pre 3D Gaussian splatting, zdroj: [10]

Posledné zo spomenutých metód sa dá považovať za istú generalizáciu prvej. Tieto metódy sú veľmi rýchle, aj keď nie natoľko presné, ako väčšina spomenutých. Vyžadujú značne veľké dátové tréningy, aby boli schopné spracovať rôzne typy scén. Sú schopné generovať 3D scény dokonca aj z jedného obrázka a môžu nájsť veľké uplatnenie v robotike a rozšírenej realite. Existujú aj nástroje dostupné online, ktoré z jedného obrázka vytvárajú model ako napríklad Adam CAD [11].

2.1.3 Softvérové nástroje a knižnice

COLMAP je open source program na 3D rekonštrukciu, ktorý vyvinul Johannes L. Schrönerberger. Celý kód je dostupný v repozitári na GitHubu a nakoľko projekt je licencovaný pod BSD licenciou, dovoľuje používateľom zmeny takmer bez obmedzení. Dá sa v ňom pracovať z konzolového aj grafického rozhrania ako vidíme na Obrázok 2.5 a ponúka širokú škálu nástrojov na rekonštrukciu z usporiadaných aj nezoradených kolekcii obrázkov. Jeho súčasťou sú dva moduly: postupnosť úloh pre SfM a pre MVS. Program dokáže, ako výstup vrátiť husté aj riedke mračno bodov, parametre kamery pre všetky formáty, normálové mapy aj hĺbkové mapy, reporty o kvalite ale aj mriežku zrekonštruovaného modelu, ak si ju používateľ zvolí.



Obrázok 2.5 GUI programu COLMAP s rekonštruovaným objektom, zdroj: [12]

OpenCV je pravdepodobne najrozšírenejšia knižnica pre spracovanie obrazu a počítačové videnie. Nejedná sa teda o samostatný plnohodnotný program ale o sadu stoviek funkcií, ktoré môžu byť použité ako stavebné bloky vlastného nástroja na 3D rekonštrukciu. Celá knižnica je tvorená modulmi – menšími knižnicami zameranými na užšiu oblasť spracovania obrazu. Je napísaná v jazyku C++ avšak má rozhrania pre Python. Veľa sa používa pri implementáciách rozšírenej a virtuálnej reality, v robotike a autonómnych systémoch či priemyselnom videní, ale aj vo výučbe počítačového videnia a spracovania obrazu. S jej pomocou dokážeme implementovať kalibráciu


kamier, trianguláciu, stereo vizuálne spracovanie, výpočty disparity, epipolárnu geometriu a väčšinu základných metód 3D rekonštrukcie [13].

MiDaS je neurónová sieť vyvinutá Intel Labs v spolupráci s Facebook Research na odhad hĺbky z jedného obrázka. Sieť bola trénovaná na veľkom množstve rôznych kolekcií obrázkov, vďaka čomu ide o veľmi robustnú metódu. Najmodernejšie verzie tejto neurónovej siete využívajú architektúry Dense Prediction Transformers, multi-scale predikciu, relatívnu normalizáciu hĺbky a extrakciu naučených parametrov. Vďaka viacerým kolekciám obrázkov pri učení je sieť schopná generalizovať a aj pri tom zachytiť jemné detaily. Vstupom pri použití MiDaS je jeden obrázok a výstupom relatívna hĺbková mapa, normalizovaná na interval $[0, 1]$ ale aj hrany, kontúry a segmenty podľa vzdialenosti. Nejedná sa však o absolútnu metriku hĺbky ide len o odhad, i keď značne presný, ktorý sa dá následne prekalibrovať podľa známej škály. MiDaS sa vo veľkom používa pri NeRF na lepšiu inicializáciu kamier. Tiež sa uplatňuje v aplikáciách virtuálnej reality a strojovom videní, ale aj pri generovaní hĺbkových máp pre 2,5D rendering.



Obrázok 2.6 Kvalitatívne výsledky testu siete MiDaS, zdroj: [14]

MVSNet je hlboká neurónová sieť pre MVS. Je medzi prvými v generovaní hĺbkovej mapy z ľubovoľného množstva obrázkov, použití diferencovateľného warpingu či tvorbe 3D objemu nákladov pomocou hlbokého učenia. V čase keď vznikla sa radila na prvú priečku v rankingoch online benchmarku [15].



Obrázok 2.7 Postupnosť krokov pri MVSNet, zdroj: [5]

2.2 Fotogrametria

Termínom fotogrametria označujeme celú oblasť, vedeckú disciplínu, množinu metód, ktoré z 2D fotografických snímok získavajú informácie o vlastnostiach, polohe a tvaroch objektov a prostredia, pomocou geometrie rekonštruujú 3D scénu. Pre dosiahnutie výsledkov fotogrametrický postup kombinuje geometriu, matematiku, počítačové videnie, optiku a najmodernejšie aj neurónové siete a hlboké učenie čím spája tieto metódy do jedného uceleného celku alebo postupu.

2.2.1 História

Počiatky fotogrametrie siahajú už k počiatkom fotografie v 18. storočí, kde boli prvé pokusy využiť fotografie na počítanie rozmerov v architektúre budov a mapovanie krajiny pre armádu. Na prelome 19. a 20. storočia začali vznikať aj prvé systémy určené špeciálne na túto úlohu. Nemecký architekt Meydenbauer v tomto období vytvoril archív s tisíckami metrických fotografií dôležitých Pruských pamiatok, čo môžeme považovať za ranné prípady využitia fotogrametrie na zachovávanie kultúrneho dedičstva. Koncom 19. storočia vznikli prvé skutočne relevantné topografické mapovania a navrhnuté analytické riešenia pre potreby tohoto typu fotogrametrie.

Skutočne veľký prielom prišiel na úplnom začiatku 20. storočia, kedy po dôležitých objavoch vznikol stereokomparátor - zariadenie schopné zaznamenať meráciu značku v dvoch obrázkoch. Digitálne spôsoby neboli dostupné alebo pomalé preto sa v rámci celého storočia, využívali predovšetkým analógové výpočty a vznikalo mnoho automatizovaných nástrojov na tvorbu kontúr. Súčasne prebiehal veľký rozmach avioniky, ktorá umožnila fotografovanie takmer akýchkoľvek oblastí planéty vo veľkom tempe. Toto v značnej miere prispelo aj k napredovaniu rozvoja fotogrametrie, i keď využitie v oblasti stereo-fotogrametrie na tvorbu komplexných modelov a presnej geometrie nebolo možné.

V úvodných desaťročiach 20. storočia medzi najväčšie nedostatky patrili nedostatok kvalitných kamier a preto sa toto obdobie mnohí odborníci zamerali práve na výskum a vývoj nových snímacích zariadení. V medzivojnovom období začala Švajčiarska polícia využívať jedno z vynájdených stereometrických snímacích zariadení na mapovanie miest nehôd.

V päťdesiatych rokoch 20. storočia sa fotogrametria presunula prevažne do oblasti analytického využitia, ktoré umožnil predovšetkým nástup digitálnych zariadení a

prechod od analógových metód k analytickým a numerickým metódam, obzvlášť analytická triangulácia. S narastajúcim výkonom počítačov prišla aj možnosť zakomponovať ich do fotogrametrického procesu a vznikali prvé stroje schopné analyticky zrekonštruovať objekt fotogrametrie do numerickej podoby. Rozmach balistického priemyslu so sebou priniesol vývoj novej metódy, ktorá sa dodnes vo veľkom využíva pri fotogrametrii, algoritmus *bundle adjustment*.

Tento posun predstavuje kľúčový míľnik v rozvoji fotogrametrie, nakoľko vyriešil mnohé problémy brzdiace posun. Do tohto objavu bolo nutné používať špeciálne snímacie zariadenia, ktoré boli často drahé a určené na veľmi špecifickú úlohu. *Bundle adjustment* umožnil použitie takmer akéhokoľvek bežne dostupného snímacieho zariadenia. Tradičná stereo fotogrametria sa pomaly prestala využívať a nastúpili systémy využívajúce analýzu viacerých fotografií.

Osemdesiate roky priniesli rozvoj vo využití opticko-elektrických senzorov a spolu s vývojom počítačov vznikla možnosť tvorby digitálnych fotografií a s ňou započala éra digitálnej fotogrametrie. Analógový videosignál začalo byť možné digitalizovať a tak prišiel aj vývoj v oblasti fotogrametrie v reálnom čase a videogrametrie. Vznikli prvé zariadenia s vysokou presnosťou pre priemyselné využitie.

Spolu s neustálym progresom vo vývoji digitálnych kamier vznikali zariadenia, ktoré sa snažili vyhnúť nízkej kvalite digitálnych videokamier a nahrádzali video vysokokvalitnými fotografiami rekonštruovaného objektu z rôznych uhlov. Rozširovali sa aj softvérové možnosti a za uplynulé desaťročia vzniklo mnoho systémov fungujúcich online aj offline.

Posledná dekáda je výrazne ovplyvnená nástupom umelej inteligencie, pričom neurónové siete v rôznych podobách a s rôznymi úlohami našli využitie aj v oblasti fotogrametrie. Tieto nové metódy výrazne posúvajú hranicu v rýchlosti a presnosti spracovania vstupných dát na výsledné digitálne 3D objekty. Hoc tradičné postupy majú stále svoje miesto, umelá inteligencia má potenciál dosiahnuť v oblasti rekonštrukcie neprekonateľne lepšie výsledky [16].


2.2.2 Princípy, geometrické modely a výpočty

Medzi najtriviálnejšie základné princípy fotogrametrie patrí centrálna projekcia, ktorá objekty z reálneho cez projekčný bod, obvykle objektív kamery, projektuje na obrazovú

rovinu. Rovnica a podstata je popísaná vyššie pri opise postupu SfM, ktorého je princíp centrálnej projekcie ústrednou súčasťou.

Základom celej fotogrametrie je princíp triangulácie, ktorý umožňuje na základe dvoch alebo viacerých 2D projekcií určiť polohu bodu v trojdimenzionálnom priestore. V praxi sa využívajú dve a viaceré kamery/pohľady, ktoré zachytávajú rovnaký bod z rôznych pozícií. Následne sa s využitím informácií o polohe a orientácii kamier určí priesečník projekčných lúčov, ten predstavuje bod v trojdimenzionálnom priestore.

Ďalším dôležitým princípom je epipolárna geometria. Tá pri zachytávaní rovnakého bodu v trojdimenzionálnom priestore opisuje vzťah medzi dvoma kamerami, tým umožňuje určiť kde sa bod z jedného obrázku nachádza v rámci druhého. Medzi dvoma rôznymi obrazmi - perspektívami sa vytvorí epipolárna priamka, ktorá vymedzí všetky možné pozície bodu, ktorý hľadáme (viď. Obrázok 2.8). Epipolárnu geometriu popisuje fundamentálna matica, ktorá závisí od vnútorných a vonkajších parametrov kamier.




Obrázok 2.8 Epipolárna geometria, zdroj: [17]

Vnútorné parametre kamery (viď. Obrázok 2.9) sú hodnoty, ktoré popisujú akým spôsobom kamera transformuje zachytávaný reálny svet do obrázkov. Obvykle ich získame z kalibrácie kamery a pre vykonanie presnej rekonštrukcie sú nevyhnutné. Patrí sem:

- ohnisková vzdialenosť (f),
- centrálny bod (c_x, c_y),
- skreslenie (distortion).

Vonkajšie parametre kamery (vid'. Obrázok 2.9) sú hodnoty, ktoré určujú aká je pozícia a orientácia kamery v trojdimenzionálnom priestore a aká je jej rotácia a translácia.



Obrázok 2.9 Vonkajšie a vnútorné parametre kamery, zdroj: [18]

Kombináciou vonkajších a vnútorných parametrov kamery vytvoríme maticu kamery, ktorá sa využíva vo výpočte projekcie.

Medzi kľúčové výpočtové algoritmy patria už spomínané a popisované SfM a MVS, nemenej dôležité a pomerne známe sú aj algoritmy bundle adjustment a RANSAC.

Bundle adjustment je optimalizačný algoritmus, ktorý pomáha minimalizovať chybovosť projekcie medzi 2D a 3D. Zohľadňuje všetky vstupné obrázky a body v trojdimenzionálnom priestore počas nelineárnej optimalizácie, ktorá zabezpečí, že výsledný model je čo možno najpresnejší.

RANSAC je pomerne robustný algoritmus využívaný predovšetkým ak sú dáta znečistené chybami. Pomocou náhodných výberov podmnožín dát a následného

testovania, opakovane hľadá najlepšie riešenie. Vieme ním odhadnúť napríklad fundamentálnu maticu, trianguláciu a kalibráciu kamier.

2.2.3 Využitie fotogrametrie vo vede a praxi

Fotogrametria má širokú škálu oblastí, kde môže byť použitá a pomôcť zefektívneniu, zlacneniu a urýchleniu rôznych procesov.

V oblasti dopravy sa využíva na rôzne kontroly výroby, tvarov a veľkostí vozidiel a lodí, predovšetkým pri bezpečnosti alebo reverznom inžinierstve. Pomáha pri návrhu systémov pre vodičov, ale aj kalibrácii výrobných robotov.

V leteckom priemysle je využívaná na meranie antén a zrkadiel, ale tiež na kontroly a simulácie v podmienkach mimo planétu.

Pri architektúre a zachovávaní kultúrneho dedičstva mapuje a umožňuje merať celé budovy alebo výkopové oblasti. Pomáha pri návrhu vizualizácii, ako nástroj na jednoduché rekonštruovanie existujúcich objektov, rekonštrukciu neúplných či poškodených štruktúr.

V inžinierstve pomáha pri meraní existujúcej infraštruktúry od potrubí, tunelov a baní až po cesty, železničné trate alebo cele obývané oblasti. Pomáha pri tvorbe modelov pre simulácie nehôd, vývoja porúch a deformácií.

Je veľmi užitočná v zdravotníctve pri rekonštrukcii a meraní kostí a zubov, pri plastickej chirurgii a neurochirurgii. Tiež je možné ju využiť pri analýze pohybu aj mikroskopických rozboroch alebo dokonca ako nástroj pri operáciách asistovaných počítačom.

2.3 Hĺbkové mapy

2.3.1 Definícia a princíp tvorby

Hĺbková mapa je dvojrozmerná reprezentácia scény v ktorej každému pixelu prislúcha hodnota rovná vzdialenosti k bodu definovanom v trojrozmernom priestore. Obvykle sa jedná o vzdialenosť od zachyteného objektu ku kamere.

Tvorba hĺbkovej mapy závisí od počtu vstupných obrazov do metódy na jej získanie. Jednou štandardne využívanou možnosťou je použitie dvoch snímok, teda stereo videnia.

V prípade MVS metód sa využíva väčší počet vstupných obrázkov vyhotovených z rôznych uhlov pohľadu na cieľový objekt. Tieto metódy sú zväčša presnejšie a výsledné hĺbkové mapy sú detailnejšie.


Momentálne sa čoraz populárnejšou stáva metóda tvorby hĺbkovej mapy z jedného vstupného obrázka. Tieto metódy využívajú neurónové siete s hlbokým učení, ktoré sa natrénujú na veľkých datasetoch a následne sú schopné odhadnúť hĺbku aj z jediného obrázka a to s veľmi dobrými výsledkami.

2.3.2 Spôsoby získavania hĺbkových máp

Jednou z klasických metód na získanie hĺbkovej mapy je stereo videnie. Pri tomto spôsobe sa medzi dvoma vstupnými obrázkami počíta disparita. Tá je následne použitá v geometrickom vzorci, ktorého výsledkom je hĺbka:

$$Z = \frac{f \cdot B}{d} \quad (2.3)$$

Do rovnice vstupujú okrem disparity aj parametre f - ohnisková vzdialenosť a B - vzdialenosť medzi dvoma kamerami (viď. Obrázok 2.10). Tento výpočet je pomerne nenáročný a preto je možné využívať túto metódu v robotike alebo autonómnych systémoch, kde je dôležité aby výpočet bežal v reálnom čase. Je však kľúčové aby vzájomné posunutie vstupných snímok bolo vhodné a dostatočné prekrytie tak umožnilo výpočet. Tiež je závislé od kvality snímacích zariadení.



Obrázok 2.10 Parametre pre výpočet disparity, zdroj: [19]


Iným prístup využíva metóda Time of Flight (ďalej len ToF), ktorá meria ako dlho trvá svetelnému signálu sa dostať od snímacieho zariadenia k objektu a späť do snímača.

Snímacie zariadenia ToF sú špeciálne a využívajú infračervené alebo laserové lúče. Táto metóda je hojne využívaná v robotike, 3D skenovaní alebo aj v biometrických aplikáciách. Výhodou ToF metódy je jej rýchlosť a presnosť bez závislosti na osvetlení avšak býva citlivá na šum a má nižšie rozlíšenie v porovnaní napríklad so stereo videním alebo štruktúrovaným svetlom. Tento prístup implementovaný naprieč rôznymi technológiami a postupmi jeho primárnym cieľom je však predovšetkým zistenie hĺbky.

Metóda so štruktúrovaným svetlom funguje na princípe projekcie vzoru (štandardne mriežky, čiary a pod.) na snímaný povrch a následná analýza spôsobu ako sa táto štruktúra deformuje na 3D objekte. Uplatnenie má obzvlášť v 3D skenovaní, ale aj pri rozpoznávaní tváre alebo kontrole kvality. Výhodou je vysoká presnosť na malých vzdialenostiach a rýchla rekonštrukcia snímaného povrchu. Hlavné obmedzenia predstavuje nutnosť kontrolovať svetelné podmienky, nakoľko metóda je citlivá na svetelné rušenie a je ju možné využívať len na relatívne malú vzdialenosť.

2.3.3 Formáty reprezentácie a vizualizácie

Pravdepodobne najčastejší formát pre reprezentáciu hĺbkovej mapy je jednoduché dvojrozmerné pole – matica, ktorá pre jednotlivé pixely obsahuje hodnoty pre reprezentáciu hĺbky. Tieto hodnoty môžu byť reálne vzdialenosti, absolútne hodnoty alebo aj normalizované hodnoty do intervalu od 0 po 1 (viď. Obrázok 2.11).



Obrázok 2.11 Ukážka hĺbkovej mapy vytvorenej pomocou neurónovej siete MiDaS uložená ako PNG súbor

Ukladať sa môžu napríklad ako bežné obrázkové formáty JPEG, PNG alebo TIFF, ktoré v pixeloch majú priamo hĺbku ako intenzitu. Ich nevýhodou môže byť

predovšetkým nutnosť dodatočného skenovania pri niektorých metódach 3D rekonštrukcie. Existujú aj špecifické formáty pre hĺbkové mapy ako DPT alebo EXR vhodné predovšetkým pre špecializované softvéry vyžadujúce takýto formát. Hĺbková mapa môže byť uložená aj vo formátoch PLY, OBJ a XYZ, ktoré sú typické pre 3D modely, kedy sa javí ako mračno bodov. Niektoré rekonštrukčné programy si môžu hĺbkové mapy ukladať vo vlastných binárnych súboroch, ktoré sú potom obvykle čitateľné len v daných programoch.

Vizualizovať hĺbkovú mapu môžeme napríklad ako šedo-tónový obrázok otvoriteľný v bežných prehliadačoch obrázkov. Rovnaký spôsob prehliadania využijeme pre vizualizácie využívajúce farebné škály priradené k hodnotám mierky. V programoch na prehliadanie 3D modelov zas vieme zobraziť hĺbkové mapy, ak sú vo formáte mračna. V analytických a numerických riešeniach je potom často praktické mať vizualizovanú hĺbkovú mapu ako histogram na kontrolu jej kvality.

3 ANALÝZA A NÁVRH RIEŠENIA

3.1 Preskúmanie možností generovania hĺbkových máp z obrazových dát

Hĺbkové mapy je možné generovať a získavať pomocou rôznych dostupných metód. Pomocou algoritmov, ktoré sú schopné vytvoriť hĺbkové mapy pomocou kalibrovaných snímok, kedy presne poznáme hĺbku Z , alebo pseudo hĺbku, alebo sa hĺbka získa pomocou predtrénovanej neurónovej siete. Každý z týchto prístupov má svoje špecifiká, o ktorých si povieme v nasledujúcich podkapitolách.

3.1.1 Hĺbkové mapy a 3D rekonštrukcia v Colmap

Ako klasický nástroj na 3D rekonštrukciu sa Colmap zameriava na extrahovanie a následnú fúziu hĺbkových máp z viacerých obrázkov rovnakého objektu pomocou triangulácie. Má samostatnú sadu procesov pre SfM a MVS, ktoré spoločne vytvoria zo sady obrázkov výslednú rekonštrukciu podľa nastavenia používateľa. Do procesov SfM patria predovšetkým:

1. Detegovanie a spájanie príznakov (SIFT/ORB)
2. Rekonštrukcia vnútorných a vonkajších parametrov kamier
3. Tvorba riedkeho mračna bodov
4. Pomocou bundle adjustment sa optimalizuje

A do procesov MVS sa radia:

1. Zo sady snímok sa vypočítajú hĺbkové mapy
2. Použitie PatchMatch MVS na získanie hĺbkových máp
3. Fúzia dát z hĺbkových máp a transformácia do hustého mračna bodov

Celý postup rekonštrukcie sa dá vykonávať priamo cez jednoduché GIU, ktoré ponúka možnosť vybrať a vyladiť procesy, ktoré sa vykonávajú nad zvoleným datasetom. Postup procesu je možné sledovať vo výpisoch a tiež v okne scény, ktorá sa postupne tvorí. Aplikácia ponúka aj možnosť všeobecného - automatického postupu rekonštrukcie. Výsledky je možné kontrolovať priamo v GUI a následne si vyexportovať to čo potrebujeme.

Colmap však možno využiť aj pomocou príkazového riadka s využitím príkazov definovaných v dokumentácii projektu na webových stránkach. Takýto prístup umožňuje vytváranie skriptov a sekvencií príkazov, ktoré zabezpečujú proces 3D rekonštrukcie na pozadí, bez nutnosti použitia GUI. Výsledky jednotlivých krokov rekonštrukcie sa ukladajú a je možné ich použiť na ďalšie spracovanie. Ich prípadné prehliadanie je možné či už s použitím už spomenutého GUI Colmap alebo v iných vhodných programoch, prípadne jednoduché textové súbory sa dajú prehliadať a aj upravovať v textových editoroch ako poznámkový blok alebo Notepad++.

Samotné hĺbkové mapy sa ukladajú ako kombinácia textových a binárnych dát a najjednoduchšie je prehliadanie priamo v GUI prípadne je pomerne jednoduché načítať ich pomocou Python skriptu či v prostredí Matlab. Za poznamenanie stojí aj fakt, že Colmap neumožňuje využitie hĺbkových máp, ktoré nevytvoril on sám.

Dôležitým výstupom z postupu sú predovšetkým mračná bodov (vytvoriť možno riedke aj husté mračno) alebo aj výstup v podobe textúrovanej mriežky či modelu.

Medzi hlavné slabiny pri Colmap patria predovšetkým pomerne vysoké nároky na výpočtovú silu a dostupnú pamäť a to obzvlášť pri väčších a komplexnejších scénach. Tiež je kľúčové aby vstupné snímky mali dostatočnú mieru prekrývajúceho sa obsahu nakoľko nejde o inteligentný, či učiaci sa nástroj, ale o rozsiahle matematické výpočty v algoritmoch. Od procesu spracovania datasetov s väčším počtom obrázkov sa dá očakávať pomerne dlhá doba behu.

Autori veľa využívali a vyladľovali tento nástroj na veľkých scénach budov, ulíc či celých mestských štvrtí a preto je predpoklad, že tento nástroj pomerne dobre zvládne exteriérové sady obrázkov.

3.1.2 Hĺbkové mapy a 3D rekonštrukcia s OpenCV a Meshroom

Knižnice OpenCV obsahuje viacero algoritmov typicky využívaných pri SfM a MVS. V tomto balíku algoritmov sú aj také, ktoré možno využiť na výpočet a tvorbu hĺbkových máp a následne tieto hĺbkové mapy použiť pri tvorbe mračna bodov. Knižnica nemá kompletný systém na rekonštrukciu, ponúkal len stavebné bloky na tvorbu takýchto nástrojov, preto samostatné využitie knižnice nie je riešením na naplnenie cieľov práce. Ako jedna možnosť je vytvoriť nový nástroj z algoritmov knižnice čo však taktiež nie je cieľom tejto práce. Ako možnosť sme teda zvolili použitie nástroja, ktorý využíva algoritmy z knižnice OpenCV a dokáže pracovať s hĺbkovými mapami.

Meshroom je softvér na 3D rekonštrukciu postavený na frameworku AliceVision, ktorý využíva princíp uzlov na skladanie sekvencie krokov v procese rekonštrukcie. Využíva knižnicu OpenCV a technológiu NVIDIA CUDA. Softvér ponúka moderne GUI s predpripravenými sekvenciami krokov, ale aj možnosťou budovať celý proces od začiatku. Do editora sa pridávajú jednotlivé uzly – bloky s funkcionalitou algoritmov a sekvenčne sa poprepájajú ich vstupy a výstupy, tak aby postupom cez vytvorenú sekvenciu vznikol výstup, ktorý si používateľ nadefinoval. Každému bloku je možné meniť parametre, ktoré algoritmus využíva pri výpočtoch. Vystavanú sekvenciu je možné spustiť ako celok alebo krok po kroku spúšťať jednotlivé bloky za sebou. V GUI sa zobrazuje aj vznikajúca rekonštrukcia scény a rovnako je možné si prehliadať vytvorené hĺbkové mapy po dobehnutí príslušného uzla. Meshroom umožňuje aj použitie hĺbkových máp z iných zdrojov. Ak je do sekvencie zaradený uzol na tvorbu hĺbkových máp, je možné ich použiť na tvorbu výsledného mračna alebo modelu.

Meshroom tiež ponúka možnosť pracovať s ním len cez príkazový riadok a teda je možné napísať skript na 3D rekonštrukciu. Samotný beh však môže v niektorých prípadoch uprednostniť základné nastavenia jednotlivých uzlov v danej sekvencii, preto je písanie parametrov sekvencie v skripte občas nefunkčné. Meshroom však umožňuje sekvenciu vytvorenú v GUI uložiť a vyexportovať a pri volaní z príkazového riadka použiť práve túto vyexportovanú a nastavenú sekvenciu bez potreby písania jednotlivých krokov.

Meshroom je vhodný obzvlášť na rýchle prototypovanie a je pomerne dobrým úvodným programom pre začiatočníkov. Nevýhodou podobne ako pri Colmap je pomerne vysoké nároky na zdroje avšak je predpoklad, že môže dosiahnuť lepšiu rýchlosť i keď za cenu nižšej kvality v porovnaní s Colmap.

3.1.3 Hĺbkové mapy a 3D rekonštrukcia s MiDaS

Neurónová sieť MiDaS využíva Dense Prediction Transformer (ďalej len DPT) a hlboké učenie na odhadovanie relatívnej hĺbky z jedného obrázka. Táto možnosť predstavuje veľký posun od klasických metód stereoskopie avšak prináša so sebou úskalia, ktoré sa momentálne rieši pomerne náročne.

Architektúra DPT počíta relatívnu hĺbku pixel po pixeli a následne do celku poskladané pixeli tvoria výslednú hĺbkovú mapu. Na vstupnom obrázku sa sieť naučí rozpoznávať objekty, hrany a textúry, pričom transformery veľmi efektívne zachytili

závislosti medzi pixelmi v obrázku, čo sa využíva na odhad hĺbky. Extrahujú sa funkcie a DPT ich prevedie na predikciu hĺbky, teda vzdialenosť bodu od kamery normalizovanú do intervalu od 0 do 1. Model bol trénovaný na veľkých datasetoch čo umožnilo značnú generalizáciu a takto predtrénovaný model by mal zvládať najrôznejšie typy scén zachytených na vstupnom obrázku.

Avšak táto metóda nie je sama o sebe schopná vykonať kompletnú rekonštrukciu 3D scény. Na vstup príde obrázok a ako výstup je jeho odhadnutá hĺbková mapa, nie mračno alebo model. Na toto je potrebné vykonať niekoľko ďalších krokov a využiť hĺbkové mapy. Existujú repozitáre a projekty zamerané na využitie výstupov z MiDaS na vytváranie mračien bodov avšak aj tieto projekty obvykle pracujú s jednou vstupnou snímkom nie s datasetmi pozostávajúcimi z mnohých snímok rovnakého objektu. Výsledné mračná bodov sú preto často len riedke a majú dáta len z pohľadu vstupnej snímky pri ostatných pohľadoch sú takmer prázdne a značne deformované. Na využitie viacerých hĺbkových máp pri tvorbe jedného modelu je problémom práve relatívna hĺbka. Výsledné mapy nemajú vzájomné vzťahy a ich kombinovanie je problematické aj pri použití vopred vypočítaných parametrov kamier pomocou iných softvérov ako napríklad Colmap.

Samotná tvorba hĺbkových máp pomocou predtrénovaného modelu nie je náročný proces a je predpoklad, že nebude náročná na zdroje a celý beh aj nad väčšími datasetmi bude pomerne rýchly. Výsledné hĺbkové mapy sa dajú uložiť a prehliadať ako obrázok s hodnotami pixelov od podľa vzdialenosti od kamery.

3.1.4 Hĺbkové mapy a 3D rekonštrukcia s MVSNet

Ako samotný názov MVSNet napovedá, táto metóda vychádza z multi view stereo a na tvorbu hĺbkových máp využíva neurónová sieť s hlbokým učením na základe viacerých obrázkov s pohľadmi na rekonštruovaný objekt.

Zo vstupných obrázkov sa pomocou konvolučnej neurónovej siete získavajú príznaky pre 2D funkcie. Následne vzniká 3D tenzor, v ktorom pre každý pixel je priradený cost (náklady) pre rôzne hodnoty hĺbok. Pomocou vopred natrénovanej neurónovej siete sa gradientovým poklesom môže optimalizovať. Následne sa 3D konvolučnou sieťou tvoria v rôznych pohľadoch vzory a predikuje sa čo najpresnejšia hĺbka a vykonáva regularizovanie dát. Pomocou regulovaných nákladov a následnej predikovanej hĺbky v

rôznych pohľadov sa následne vytvára veľmi presná rekonštrukcia scény v podobe hustého mračna bodov alebo textúrovanej mriežky či modelu.

Tento model bol trénovaný, ako celok preto pri použití natrénovaného modelu nie je nutné vykonávať špecifické zmeny a optimalizácie. Vzniknuté hĺbkové mapy a výsledné mračná a modely sú vysokej kvality a to obzvlášť aj pri veľkých vstupných datasetoch a to aj pri snímkach, ktoré nie sú perfektne zarovnané. Na druhej strane medzi najväčšie slabiny patrí nutnosť vysokovýkonného GPU, či už pri tréningu ale aj následnom používaní. Model tiež máva problémy pri jednoliatych objektoch so slabými textúrami a nedostatkom komplexnejších tvarov.

3.1.5 Hĺbkové mapy a 3D rekonštrukcia s PatchMatchNet

Jedná sa o vylepšenú verziu MVSNet architektúry, ktorá používa algoritmus Patch Match na zrýchlenie a spresnenie odhadu hĺbky pomocou hľadania podobných oblastí v spracovávaných vstupných snímkach. V modeli sa integruje do procesu tvorby cost value (nákladov) a urýchlíuje tento proces. Výsledkom je lepšia regularizácia a aj odstránenie šumov, čo vedie k väčšej efektívnosti celej rekonštrukcie. Podobne ako klasické MVSNet však má značné požiadavky na výkon GPU a kvalita výstupu závisí od kvality vstupných obrázkov, kde šum a svetelné vlastnosti zohrávajú zásadnú rolu.

3.1.6 Výber vhodných datasetov

Jedným zo zásadných aspektov pri výslednej kvalite rekonštruovanej scény je aká je kvalita vstupných obrázkov. Pre testovanie rôznych metód rekonštrukcie je preto vhodné využiť datasety s rôznymi vlastnosťami, aby sa dalo poukázať na nedostatky jednotlivých metód, ale rovnako aj na ich silné stránky.

Prvým dôležitým aspektom je svetlo v obrázkoch. Pri vhodnom nesvietení je lepšia čitateľnosť tvarov a zreteľnejšie je možné vidieť vzdialenosti čo má vplyv pre vnímanie hĺbky. Ak je naopak svetlo nedostatočné alebo prílišné, mnohé detaily sa strácajú a je náročné správne odhadovať hĺbku. Toto sa priamo preklápa do rozdielov exteriérových a interiérových datasetov. Vonkajšie osvetlenie sa dá regulovať a vytvárať len pomerne zložito, nie je možné zamedziť vplyv prostredia, pri stálom počasí a priaznivých podmienkach, môžu byť výsledky pomerne dobré, avšak neexistuje garancia. Pri interiérových podmienkach je osvetlenie obvykle umelé a kvalita závisí od šikovnosti a znalosti toho kto ho tvorí. Pri nedostatočnom nesvietení v interiéri budú výsledky tmavé a stratia detaily.

S exteriérom a interiérom súvisí aj komplexnosť scén. Pri scénach, ktoré sú komplexné a obsahujú veľké množstvo objektov, detailov a tvarov alebo dokonca majú súčasti, ktoré sa menia či pohybujú môžu niektoré metódy 3D rekonštrukcie mať problém, no iné naopak môžu práve pri tomto excelovať. Naopak scény obsahujúce jednoduché či takmer jednoliate tvary, malé množstvo objektov či menej komplexné okolie často predstavujú pri rekonštrukcii väčšie problémy, ako sa na prvý pohľad môže zdať. Okolie, ktoré je súčasťou pri rekonštrukcii objektu môžeme využiť ako pozadie, ktoré nám pri určitých podmienkach bude slúžiť, ako nástroj na správne zarovnanie snímok medzi sebou. Takto využité pozadie je vhodné ak digitalizujeme objekt, ktorý nemá dostatočné výrazný povrch z hľadiska objemovej štruktúry a kvality textúry povrchu.

Počet snímok v datasete taktiež zohráva veľkú úlohu. Niektoré metódy vyžadujú pre dosiahnutie optimálnej kvality väčšie datasety aj keď fungovať dokážu aj s menším počtom záberov, snímok. Pri niektorých metódach väčšie počty vstupných snímok nemusia mať výrazný vplyv na zvýšenie kvality no vo všeobecnosti platí, že väčší počet snímok sa rovná lepším výsledkom. Niektoré metódy sú schopné pracovať aj s veľmi malým počtom snímok a dokonca môže stačiť aj jediný záber.

V neposlednom rade môže byť pre niektoré metódy pomocou alebo komplikáciou aj rozdiel, ak dataset vznikol pohybom kamery okolo objektu alebo bola kamera statická a pohyboval sa objekt.

V práci sme využívali päť datasetov, ktoré predstavovali rôzne objekty s rôznymi vlastnosťami povrchov a tiež reprezentovali rôzne objemové tvary.

Prvý dataset bol vytvorený pomocou mobilného telefónu a zachytáva tvarom pomerne jednoduchú sochu. Vznikol v exteriéri bez pomocného svetla rotáciou kamery okolo snímaného objektu a na snímkach sa nachádzajú aj prvky z okolia. Kombinuje zábery celku z rôznych uhlov aj zábery detailov z bližších pozícií kamery. Celkovo má sto štyri snímok.



Obrázok 3.1 Socha vo vedeckom parku UNIZA

Druhý dataset je rovnako exteriérový vznikol pomocou fotoaparátu, ktorý sa pohyboval okolo snímaného objektu bez pomocného svetla. Objektom snímania je budova a zábery neobsahujú veľa okolitých objektov a budovu zachytávajú len z úrovne osoby stojacej vedľa budovy. Celkovo obsahuje sto snímok.



Obrázok 3.2 Gerrard Hall, zdroj: [20]

Tretí dataset je interiérový a na vyhotovenie bol použitý fotoaparát, pričom sa kombinuje otáčanie objektu aj zmena polohy kamery. Snímaný objekt je lebka, ktorá má pomerne jednoduché tvary a nevýrazné textúry preto na nej je niekoľko tmavých bodov ako pomocný aspekt. Pozadie na približne polovici záberov je jednoliate a svetlo je miestami odrážané od reflexívneho povrchu. Celkovo má dataset šesťdesiatštyri snímok.




Obrázok 3.3 Model lebky, zdroj: [21]

Štvrtý dataset je interiérový a kombinuje otáčanie objektu aj zmenu polohy kamery. Snímaný objekt je ulita, ktorá má pomerne jednoduché tvary avšak farebný vzor je pomerne komplexný. Pozadie je takmer výlučne jednoliate a svetelné podmienky sú dobré bez tmavých miest či presvetlených záberov. Celkovo má dataset osemdesiatosem snímok.



Obrázok 3.4 Ulita, zdroj: [22]

Piaty dataset rovnako vznikol v interiéri a vznikol rotovaním fotoaparátu okolo objektu. Objektom snímania je trs banánov, ktorý má komplexnejšie tvary aj farebnú štruktúru. Pozadie snímok je jemne vzorkovaná textúra a svetlo je nevýrazné so vzniknutými tieňmi. Tento dataset je najmenší obsahuje len šesťsnásť snímok.



Obrázok 3.5 Trs banánov, zdroj: [22]

3.2 Návrh implementácie


3.2.1 Architektúra riešenia

Pre štyri zvolené metódy sme navrhli štyri samostatné skripty, ktoré vezmú zvolený dataset a vytvoria na výstupe mračno bodov, ktoré bude možné vizualizovať a porovnať s výsledkami ostatných metód. Pri každej metóde sme využili možnosť spúšťať celý proces rekonštrukcie z príkazového riadka a vyhnúť sa tak nutnosti pracovať v GUI, čo uľahčuje prácu pri testovaní.

Každý skript by mal spĺňať nasledovné:

- Je univerzálny natoľko aby nebola nutná úprava pre špecifické datasety, a to aj za cenu dlhšieho trvania celkového behu.
- Ako vstup dostáva sadu snímok a všetky využije pri rekonštrukcii.
- V procese rekonštrukcie sa vytvárajú hĺbkové mapy, ktoré sú následne použité pri tvorbe mračna bodov.
- Výstupom je husté mračno bodov v surovom nefiltrovanom stave.
- Nie sú nutné nijaké špeciálne vstupné údaje mimo samotné datasety.

Husté mračná bodov, ktoré tieto skripty vytvoria sa uložia do špecifikovaných priečinkov. Ich otvorenie a prípadná ďalšia úprava už nie je úlohou skriptov, sú na ňu nutné iné nástroje. Blokovú schému tohto procesu vidíme na Obrázok 3.6.



Obrázok 3.6 Bloková schéma 3D rekonštrukcie

3.2.2 Softvérové a hardvérové prostredie

Realizáciu jednotlivých experimentov sme vykonávali na domácom počítači s operačným systémom Windows 11, čomu boli uspokojené aj skripty - využívajú sa dávkové .bat súbory špecifické pre Windows. Počítač má procesor Intel Core piatej generácie s frekvenciou 4.2 GHz, operačnú pamäť typu DDR5 s veľkosťou 64 GB a frekvenciou 6000 MHz. Optimálny beh použitých metód využívajúcich technológiu CUDA zabezpečuje grafická karta NVIDIA GeForce RTX 5070 s 12 GB pamäti, 6144 CUDA jadrami a frekvenciou 28GHz.

Na písanie skriptov sa využívalo prostredie Visual Studio Code a skripty sú v jazyku Python alebo dávkové súbory systému Windows. Pre MiDaS a PatchMatchNet bolo nutné vytvoriť virtuálne prostredia venv pomocou jazyka Python.

Na zobrazovanie a porovnávanie vytvorených mračien bodov sme využívali program Cloud Compare, ktorý je voľne dostupný na stiahnutie na webe. Pri spracovaní dát z analýzy výsledkov porovnaní sme využívali prostredie Matlab s využitím študentských licencií. Mnohé použité metódy vyžadujú špecifické softvérové balíčky a knižnice, tie sú spomenuté v dokumentáciách samotných metód, väčšina metód je dostupná v podobe repozitára na GitHube, kde sme zverejnili aj výsledky, ktoré vznikli v rámci tejto práce.

4 PRAKTICKÁ ČASŤ – IMPLEMENTÁCIA


V praktickej časti popisujeme akým spôsobom sme implementovali jednotlivé metódy pomocou skriptov a dávkových súborov aj aký bol proces ladenia a vysporiadania sa s prípadnými problémami.

4.1 Generovanie hĺbkových máp tradičnými metódami


4.1.1 Implementácia Meshroom

Pôvodná idea implementácie 3D rekonštrukcie pomocou Meshroom, bola využiť rozhrnie aplikácie pre príkazový riadok a s pomocou dokumentácie vytvoriť skript používajúci hĺbkové mapy na tvorbu hustého mračna. Skript sme začali vytvárať pomocou jazyka Python so snahou o čo možno najuniverzálnejší proces rekonštrukcie. Prvým krokom bolo nájdenie vnútorných a vonkajších parametrov kamery, následne vykonával extrakciu parametrov. Na základe týchto údajov odhadol hĺbkové mapy, z ktorých potom vygeneroval husté mračno bodov.


Tento skript však nevytváral želané výsledky a po preskúmaní sme zistili, že vo viacerých krokoch ignoruje zadané parametre jednotlivých príkazov - uzlov. Prvotným riešením bolo pridanie JavaScript súboru s konfiguráciou priradzujúcou parametrom želané hodnoty a následné priradenie tohoto konfiguračného súboru do uzla. Ani toto riešenie však nebolo účinné a beh rekonštrukcie neustále vo viacerých uzloch využíval prednastavené parametre namiesto novo priradených hodnôt.



Obrázok 4.1 Sekvencia rekonštrukcie Meshroom, 1. časť



Obrázok 4.2 Sekvencia rekonštrukcie Meshroom, 2. časť



Obrázok 4.3 Sekvencia rekonštrukcie Meshroom, 3. časť

Pre vyriešenie tohoto problému sme zmenili postup, namiesto vytvorenia celej sekvencie krokov cez príkazy sme sa rozhodli zostaviť túto sekvenciu priamo v GUI (vid'. Obrázok 4.1, Obrázok 4.2 a Obrázok 4.3). Pomocou ulov sme zostavili celý proces a nastavili sme parametre tak aby bol pokiaľ možno čo najuniverzálnejší, využil hĺbkové mapy a nevytváral mriežku ani textúru, ale len husté mračno bodov ako výstup. Po otestovaní funkčnosti priamo cez GUI sme túto sekvenciu uložili .mg súbor, ktorý je možné použiť v skripte namiesto predvolenej sekvencie. Vytvorili sme nový dávkový súbor, ktorý využíva vytvorenú sekvenciu a tiež berie parametre z priloženého konfiguračného súboru. Súbor si inicializuje priečinky, v ktorých bude ukladať a pracovať. Jediným problémom, ktorý pretrváva aj po všetkých úpravách je miesto kam sa ukladá cash behu rekonštrukcie. Nejde o kritický problém, ktorý by ovplyvňoval výsledky, spôsobuje len komplikáciu v prípade, ak používateľ chce skontrolovať medzivýsledky je nútený ich hľadať v súborovom systéme počítača.

4.1.2 Implementácia Colmap

Pri implementácii Colmap sme rovnako využili dostupnosť spúšťania funkcionality cez príkazový riadok. Vytvorili sme dávkový súbor, ktorý inicializuje pracovné priečinky a nastaví potrebné parametre. Následne sa krok po kroku vykonáva rekonštrukcia. Prvou fázou je extrakcia parametrov a párovanie v rámci čoho sú nájdené vonkajšie a vnútorné parametre kamery podľa preddefinovaného typu a samotná rekonštrukcia do riedkeho mračna bodov. Aby sa zabezpečila univerzálnosť tohoto postupu, ktorá napodobuje automatickú rekonštrukciu z GUI, sú použité dva rôzne typy kamery a celý proces sa spúšťa dva krát, pričom sa vyberá verzia s lepšou kvalitou pre dosiahnutie dobrých výsledkov.

Ďalší postup je rovnaký bez ohľadu na predchádzajúce možnosti. Prebehne odstránenie skreslenia a pomocou Patch Match algoritmu sa vytvoria hĺbkové mapy. Zo vzniknutých hĺbkových máp sa v poslednom kroku spájaním vytvorí výsledné husté mračno bodov. Na záver prebehne kontrola či vznikol súbor s mračnom a aká je jeho veľkosť. V prípade potreby by nasledovalo vytvorenie textúrovanej mriežky dvoma možnými spôsobmi: použitím algoritmu s Poissonovým alebo Delaunayho mesherom.


4.2 Generovanie hĺbkových máp pomocou neurónových sietí

4.2.1 Implementácia neurónovej siete MiDaS


Neurónová sieť MiDaS je verejne dostupná a je možné ju stiahnuť na webovej stránke PyTorch. Na prácu s neurónovou sieťou bolo nutné vytvoriť v súborovom systéme pomocou programovacieho jazyka Python virtuálne prostredie venv. Po vytvorení a aktivácii sme cez príkazový riadok stiahli potrebné balíčky a knižnice nutné na beh, ktoré neskôr počas vývoja ešte aj ďalej pribúdali. Nakoľko sieť pracuje len s jedným vstupným obrázkom, ktorý použije na vytvorenie odhadovanej hĺbkovej mapy. Začiatočným bodom bolo vytvorenie jednoduchého skriptu v jazyku Python, ktorý prešiel celý priečinok so vstupnými obrázkami a každý poslal do siete MiDaS. Tá vytvorila jeho hĺbkovú mapu a skript výsledné mapy uložil.

Samotná neurónová sieť MiDaS však nie je schopná vytvoriť aj mračno bodov alebo model. Na vytvorenie mračna bodov na základe vygenerovaných hĺbkových máp je potrebné použiť ďalší nástroj. Na základe odporúčenia od vedúceho práce sme použili repozitár na GitHubu, ktorý sa venoval použitiu siete MiDaS a následnej tvorbe mračna

bodov. Tento repozitár využíva jeden vstupný obrázok aby vygeneroval hĺbkovú mapu a následne z nej vytvoril mračno bodov. Tento postup však nebol dostačujúci pre potreby tejto práce a bolo nutné urobiť úpravu, ktorá by spojila tieto čiastkové mračná vytvorené pre každý vstupný obrázok samostatne, do jedného veľkého mračna bodov. Skript vytvára hĺbkové mapy a následne aj jednotlivé mračná bodov a následne ich spája do jedného mračna pomocou RANSAC iteračného algoritmu. Problémom však je, že jednotlivé hĺbkové mapy a ani z nich vytvorené mračná (vid'. Obrázok 4.5 a Obrázok 4.6) nemajú medzi sebou nijaké vzťahy a pri ich uložení do jedného mračna nesedia orientácie ani veľkosti a preto výsledkom takéhoto spájania boli útvary, ktoré zďaleka nepripomínali objekt zachytený na vstupných obrázkoch.



Obrázok 4.4 Mračno z jednej fotografie vytvorené pomocou MiDaS



Obrázok 4.5 Mračno vyskladané z celého datasetu cez MiDaS

Na základe inšpirácie z vyššie spomenutého repozitára sme sa rozhodli vytvoriť skript, ktorý bude kombinovať postupy použité v repozitári s inou metódou na získanie údajov

o vzájomnej polohe obrázkov a kamerách. Pred samotné použitie neurónovej siete sme preto pridali iniciálne kroky z Colmap, ktoré zistia a uložia potrebné dáta. Tie neskôr skript používa pri snahe o odhadnutie polohy bodov v priestore a zostavenie jednotlivých mračien do celku. Pri viacerých iteráciách a zmenách parametrov, nastavení filtrovania a použití rôznych algoritmov výsledky mali rôzne podoby, výbuchov, kytíc, komét, atď. (viď, Obrázok 4.6). Nepodarilo sa nám však docieľiť, aby sa výsledné mračno naskladalo správnym spôsobom. Po konzultácii s vedúcim práce sme usúdili, že tento postup je príliš komplikovaný, a zameriavať sa máme predovšetkým na metódu MiDaS a jej výstupy, dodatočné spracovanie nebolo cieľom i keď sme vynaložili snahu na spojenie mračien do celku ako tomu je pri iných metódach.



Obrázok 4.6 Neúspešné výsledky rôznych iterácii skriptu pre MiDaS

4.2.2 Implementácia neurónovej siete PatchmatchNet

Pre implementovanie neurónovej siete MVSNet, sme z dôvodu lepšieho výkonu a aby sme sa vyhli problémom s kompatibilitou s aktuálnymi verziami knižníc, vybrali novšiu a efektívnejšiu verziu PatchmatchNet. Opäť bolo nutné vytvoriť pomocou jazyka Python

virtuálne prostredie venv, v rámci ktorého sa stiahli všetky potrebné závislosti a knižnice tak ako je uvedené v pokynoch v repozitári, z ktorého sme neurónovú sieť stiahli.

Podobne ako pri MiDaS aj pre potrebu správneho fungovania tejto neurónovej siete je nutné získať niektoré parametre obrázkov aj vonkajšie a vnútorné parametre kamery. Repozitár má špecifikovaný ako zdroj týchto informácií Colmap, preto sa aj tu na prípravu týchto dát využívajú práve funkcie z Colmap. Celý beh je spúšťaný pomocou dávkového súboru, ktorý najskôr inicializuje pracovné priečinky, následne vykoná prípravu dát cez Colmap. Je tu podobne ako pri samostatnej metóde s Colmap použité dvojité vytvorenie týchto údajov aby sa zabezpečilo, že výsledok bude správny.

Dávkový súbor využíva priložený skript na konvertovanie údajov z Colmap na vstupné údaje pre sieť. Nasleduje spracovanie dát neurónovou sieťou, ktorého výstupom je husté mračno bodov (viď. Obrázok P. , Obrázok P. , Obrázok P. , Obrázok P. a Obrázok 4.12).

4.3 Automatizácia spracovania dát


4.3.1 Návrh a implementácia skriptu

Počas iniciálnych testov jednotlivých metód sa ukázalo, že je nutné ich opakovane spúšťať na datasetoch, jednotlivé behy samostatných metód majú rôzne a pomerne zdĺhavé trvanie, pre každú metódu je nutné mať spustený samostatný terminál často s aktívnym virtuálnym prostredím. Pre zefektívnenie a zjednodušenie práce obzvlášť na celkových finálnych testoch sa vykryštalizovala idea vytvoriť jednoduchú aplikáciu, ktorá by umožnila spúšťať jednotlivé metódy 3D rekonštrukcie na zvolených datasetoch. Aplikácia by mala jednoduché GUI, v ktorom bude možné zvoliť jeden z momentálne dostupných datasetov (viď. Obrázok 4.7) a pomocou zaškrťovacích okienok navoliť, ktoré z dostupných metód rekonštrukcie sa majú použiť (viď. Obrázok 4.8). Po spustení sa v GUI bude zobrazovať výpis vo forme jednoduchého logu a po dobehnutí sa zaznamenajú niektoré základné informácie o behu a miestach kam sa uložili dáta (viď. Obrázok 4.9). Na pozadí bude aplikácia merať trvanie behu, spotrebu zdrojov a výstupy zaznamenávať do CSV súboru, ktorý sa po dobehnutí zapíše do príslušného priečinka.


Na vytvorenie tejto aplikácie sme využili programovací jazyk Python a napísaná je tak, aby na pridanie alebo zmenu používaných metód 3D rekonštrukcie stačilo vykonať niekoľko jednoduchých úprav, či nakopírovanie existujúcich štruktúr. Aplikácia je viazaná na špecifickú štruktúru súborového systému a pri jej dodržaní automaticky

deteguje prídanie nového datasetu. V prípade ak je viacej dostupných jednotiek GPU je možné vybrať ktorá sa použije. Aplikácia integruje jednoduchý monitor zdrojov a v prípade záujmu by malo byť možné ho rozšíriť o monitorovanie ďalších veličín.


Celá aplikácia má vytvorenú vlastné virtuálne prostredie venv, avšak ak niektorá z metód 3D rekonštrukcie vyžaduje svoje vlastné je možné upraviť skript tak aby použil to, tento princíp sme využili pri spúšťaní neurónovej siete MiDaS.



Obrázok 4.7 Dropdown na výber datasetu a GPU



Obrázok 4.8 Zaškrŕavacie možnosti metód rekonštrukcie a tlačidlá na ovládanie aplikácie



Obrázok 4.9 Sekcia pre výpis výsledkov a logu

4.4 Ukážky výsledkov


4.4.1 Výsledné surové mračná bodov z Colmap

Pri rekonštrukcii pomocou metódy Colmap vznikli mračná bodov v ktorých je jednoznačne rozoznateľné o aký objekt sa jedná, ako môžeme vidieť na Obrázok P. , Obrázok P. , Obrázok P. , Obrázok P. a Obrázok 4.10. Počet bodov v surových mračnách pre jednotlivé datasety môžeme vidieť v Tabuľka 4.1. Špeciálnym prípadom v rekonštrukcii je pri metóde Colmap dataset socha (viď. Obrázok 4.10), pri ktorom metóda v nastavení približujúcom sa automatickej rekonštrukcii z GUI vytvorila rekonštrukciu nielen ústrednej sochy, no v značnej miere aj celého okolia viditeľného na

fotografiách. Tento výsledok nie je prekvapivý, nakoľko metóda sa v značnej miere vyvíjala s prihliadnutím na využitie pri rekonštrukcii scén ulíc a mestských častí.

Tabuľka 4.1 Počty bodov v mračnách z Colmap

Názov datasetu	Počet bodov vo výslednom mračne
Socha	2 710 166
Gerrard Hall	3 573 426
Lebka	757 847
Ulita	1 696 159
Trs banánov	858 623




Obrázok 4.10 Mračno z Colmap - dataset socha

4.4.2 Výsledné surové mračná bodov z Meshroom

O výsledných mračnách z metódy Meshroom môžeme povedať, že sú redšie no napriek tomu je stále jednoznačne možné identifikovať čo bolo objektom rekonštrukcie, ako môžeme vidieť na Obrázok P. , Obrázok P. , Obrázok P. , Obrázok P. a obzvlášť dobre vidieť nižšiu hustotu v niektorých oblastiach na Obrázok 4.11. Celkové počty bodov v surových mračnách pre jednotlivé datasety sú uvedené v Tabuľka 4.2.

Tabuľka 4.2 Počty bodov v mračnách z Meshroom

Názov datasetu	Počet bodov vo výslednom mračne
Socha	1 342 950
Gerrard Hall	2 626 261
Lebka	63 377
Ulita	627 200
Trs banánov	390 638



Obrázok 4.11 Mračno z Meshroom - dataset lebka

4.4.3 Výsledné surové mračná bodov z PatchmatchNet

O mračnách vytvorených metódou MVSNet môžeme konštatovať, že majú vysoký počet bodov s vysokou hustotou avšak ako môžeme vidieť na Obrázok P. , Obrázok P. , Obrázok P. a Obrázok P. v mračnách sa nachádzajú pomerne často aj rôzne artefakty. Jednotlivé počty bodov, uvedené v Tabuľka 4.3, sú vyššie aj o celý rád oproti mračnám z iných metód. Špeciálne problémovou situáciou pri tejto metóde rekonštrukcie sa ukázal byť dataset s malým počtom fotografií. Metóda MVSNet mala problém zrekonštruovať objekt zachytený na fotografiách a vzniklo mračno so značne nekompletnou geometriou, a to až v takej miere, že nie je jednoznačne rozlíšiteľné aký objekt je rekonštruovaný ako môžeme vidieť na Obrázok 4.12.

Tabuľka 4.3 Počty bodov v mračnách z PatchmatchNet


Názov datasetu	Počet bodov vo výslednom mračne
Socha	26 346 740
Gerrard Hall	67 562 162
Lebka	12 646 230
Ulita	42 888 749
Trs banánov	626 249



Obrázok 4.12 Mračno z PatchmatchNet - dataset trs banánov

4.4.4 Výsledné surové mračná bodov z MiDaS

Ako sme už spomínali v kapitole o tvorbe skriptov, výstupy z metódy MiDaS boli v prípade spojených mračien chaotické a ich tvar sa ani čiastočne nepribližoval ku geometrii rekonštruovaných objektov. Avšak menšie mračná vytvorené z jednotlivých fotografií sa približujú geometrii rekonštruovaného objektu aspoň v miere, ktorá vo väčšine prípadov dovoľuje rozoznať o aký objekt sa jedná ako môžeme vidieť na Obrázok P. , Obrázok P. , Obrázok P. , Obrázok P. a Obrázok 4.13.



Obrázok 4.13 Mračno z jedného obrázka z MiDaS - dataset ulita

4.4.5 Referenčné mračná

Pre porovnanie kvality výsledkov je pri každom datasete potrebné mať alebo vytvoriť aj jedno referenčné mračno. Medzi typické zdroje referenčných mračien sa využívajú skeny rekonštruovaných objektov alebo hotové vysokokvalitné fotogrametrické alebo skenované rekonštrukcie od autora datasetu. Nakoľko použité datasety neumožňovali vytvoriť si sken rekonštruovaného objektu, keďže boli nájdené na internete a ani neobsahovali referenčnú 3D rekonštrukciu od autora, bolo nutné si túto rekonštrukciu spraviť pomocou fotogrametrie. Použitý bol nástroj Agisoft Metashape, ktorý je priemyselným štandardom fotogrametrie. Pri tvorbe referenčných mračien boli zvolené najvyššie dostupné nastavenia kvality a presnosti.

5 EXPERIMENTÁLNE VYHODNOTENIE

5.1 Porovnávacie kritériá

V rámci porovnaní sa zameriame na tri oblasti – presnosť, výkon a vizuálna kvalita. Presnosť budeme analyzovať porovnávaním mračien bodov a pozerat' sa na metriky ako stredná vzdialenosť, smerodajná odchýlka a maximálna vzdialenosť. Pri výkone nás predovšetkým zaujíma čas a spotreba zdrojov. V neposlednom rade každé mračno zhodnotíme vizuálnou kontrolou a zhrnieme jeho subjektívnu kvalitu.

5.1.1 Presnosť

Pre porovnanie mračien z jednotlivých metód 3D rekonštrukcie sme použili softvér CloudCompare, ktorý poskytuje nástroje na prácu s mračnami bodov. V našom prípade sme využívali referenčné mračno, s ktorým sme porovnávali výstupy z jednotlivých metód. Z parametrov získaných pri takomto porovnaní sme následne formulovali závery, ako presne vytvorené mračná kopírujú geometriu rekonštruovaného objektu, odhliadnuc od kompletnosti a hustoty, ktoré sú predmetom následného vizuálneho hodnotenia. Už pri vizuálnej kontrole výstupov z metódy používajúcej neurónovú sieť MiDaS bolo očividné, že porovnávanie výstupov z ostatných metód nebude voči chaotickým zhlukom, ktoré vznikli spájaním jednotlivých mračien pre individuálne obrázky, nebude vhodným postupom. Potvrdením tohoto predpokladu bola úplná nemožnosť ani len korektne ich zarovnať, či už množinou bodov alebo algoritmom ICP. Z tohoto dôvodu mračná spojené do jedného celku z menších mračien z metódy MiDaS nie sú súčasťou porovnaní v CloudCompare, nakoľko výsledky nebolo možné získať. Namiesto toho vyberáme jedno čiastkové mračno vytvorené z jednej fotografie a na tom demonštrujeme, aký veľký rozdiel je oproti referenčnému mračnu ak sa podarí zarovnanie. Pre ostávajúce tri metódy sme pri jednotlivých porovnovaniach vždy uplatnili nasledovný postup:

1. Referenčné a porovnávané mračná sa nahrajú do programu CloudCompare.
2. V prípade existencie zhlukov bodov, ktoré nepatria k rekonštruovanému objektu a spôsobovali by zlyhanie zarovnania, tieto body v porovnávanom mračne odstránime.

3. Mračná približne zarovnáme najskôr manuálnym výberom aspoň štyroch párov bodov, pričom vysokokvalitné referenčné mračno bodov nastavíme ako referenčné vo všetkých nasledujúcich krokoch.
4. Nasleduje jemnejšie zarovnanie pomocou algoritmu ICP.
5. Po zarovnaní mračien necháme vypočítať vzdialenosť mračno k mračnu, z ktorej získame údaje ako stredná vzdialenosť, maximálna vzdialenosť a odchýlka.
6. Pre vypočítanú vzdialenosť získame histogram, a dáta rozloženia vzdialeností uložíme ako csv na ďalšie spracovanie.

Zo získaných informácií môžeme následne vyvodiť závery a pomocou skriptu v programe Matlab spracujeme dáta v csv súboroch na vykreslenie histogramu so zvýraznenými desiatimi percentami a získanie Hausdorffovej vzdialenosti. Hodnoty z CloudCompare uvádzané v tabuľkách a grafoch nemajú uvedenú jednotku veľkosti, program načíta mračno a veľkosť definuje podľa rozmerov definovaných v načítanom súbore. Nakoľko všetky mračná zarovnáваме algoritmom ICP, pri tomto procese sa upraví aj škála a preto jednotky neuvádzame nakoľko sa vytráca absolútna metrika a na výsledné vzdialenosti pozeráme cez normalizovanú metriku.

5.1.2 Zdroje

Ďalším dôležitým ukazateľom pri porovnávaní metód je aké sú ich požiadavky alebo zaťaženie na prostredie v ktorom sa spúšťajú. V našom prípade sa pozeráme predovšetkým na to, aké bolo trvanie behu jednotlivých metód na rovnakom zariadení pri rekonštrukcii rovnakého datasetu. Tiež využitie dostupných zdrojov ako je RAM a VRAM ale aj percentuálne zaťaženie CPU a GPU. Tieto informácie sme získali z dát v aplikácii, z ktorej sme jednotlivé metódy spúšťali.

5.1.3 Vizuálna kvalita rekonštrukcie

V neposlednom rade je pre zhodnotenie výsledkov dôležité aj subjektívne hodnotenie vizuálnej kvality celej rekonštrukcie. Kontrola úplnosti mračna, zhodnotenie nedostatkov a výhod, ktoré jednotlivé metódy dosahujú na základe vizuálnej kontroly mračien. Porovnanie výsledku jednotlivých metód vzhľadom na typ scény, ktorú zachytávajú.

5.2 Porovnanie výsledkov metód

5.2.1 Porovnanie pre dataset 1


Výsledky rekonštrukcie pre dataset socha boli pri jednotlivých metódach veľmi rozdielne v rozsahu oblasti ktorú zrekonštruovali. Pre potrebu úspešného zarovnania a následného porovnanie sme boli nútený orezať mračno len na porovnávanú oblasť. Neprebehlo nijaké filtrovanie, boli použité oblasti zo surového mračna, zodpovedajúce referenčnej oblasti.

Výsledky porovnania sú pri tomto datasete naznačujú, že výslednú rekonštrukciu v prípade metód Meshroom a MVSNet nemôžeme považovať za obzvlášť presnú. V rozmedzí top desať percent vzdialeností od referenčného modelu sa nenachádza dostatočne veľký podiel bodov aby sme mohli tvrdiť, že ide o väčšinu ako môžeme vidieť v histogramoch na Obrázok 5.2 a Obrázok 5.3. Pri metóde Colmap je tento podiel lepší, ako vidíme na Obrázok 5.1, avšak stále ostáva značná časť bodov mimo oblasť do desať percent. Pri všetkých metódach tiež v histogramoch vidíme vyšší počet bodov v maximálnej hodnote vzdialenosti. Toto rovnako ako fakt, že pri prakticky všetkých metódach je štandardná odchýlka prinajmenšom rovná alebo väčšia ako hodnota strednej vzdialenosti, jednoznačne svedčí o vysokej podobnosti s referenčným mračnom znehodnotenej nemalým počtom artefaktov – zhlukov bodov mimo hlavnú geometriu objektu. O tom istom svedčí aj hodnota maximálnej vzdialenosti (pozri Tabuľka 5.1), ktorá je aj o dva rády vyššia, ako hodnota strednej vzdialenosti. Pre porovnanie medzi metódami môžeme konštatovať, že výsledok z Colmap sa javí ako najpresnejší, má najnižšiu strednú vzdialenosť a zároveň najstabilnejší nakoľko má najmenšiu odchýlku.


Výsledok z Meshroom má najmenšiu maximálnu chybu čo sa dá chápať ako menšie množstvo artefaktov oproti ostatým metódam, avšak môže to byť spôsobené tým, že mračno je celkovo redšie a niektoré detaily chýbajú. Výsledok z MVSNet má vo všeobecnosti najhoršie hodnoty čo nasvedčuje prítomnosti šumu – riedkych zhlukov bodov rozptýlených po rôznych častiach mračna.

Tabuľka 5.1 Výsledky porovnania metód pre dataset socha


Metódy	Stredná vzdialenosť [-]	Maximálna vzdialenosť [-]	Štandardná odchýlka [-]	σ [-]	Maximálna chyba [-]
Colmap	0,0873	3,1756	0,1132	0,1506	0,2223
Meshroom	0,158	8,193	0,1509	0,2638	0,2104
MVSNet	0,174	7,1698	0,1818	0,274	0,2263



Obrázok 5.1 Graf hodnôt vzdialenosti bodov Colmap, dataset socha, na osi X hodnoty vzdialenosti od 0 do 1, na osi Y počty bodov rádovo v 10^5




Obrázok 5.2 Graf hodnôt vzdialenosti bodov Meshroom, dataset socha, na osi X hodnoty vzdialenosti od 0 do 1, na osi Y počty bodov rádovo v 10^5




Obrázok 5.3 Graf hodnôt vzdialenosti bodov MVSNet, dataset socha, na osi X hodnoty vzdialenosti od 0 do 1, na osi Y počty bodov rádovo v 10^5

5.2.2 Porovnanie pre dataset 2

Pri datase Gerrard Hall výsledky podobne ako pri datase socha obsahovali artefakty, ktoré obmedzovali možnosť zarovnať mračná pomocou algoritmu ICP. Ako môžeme vidieť na Obrázok 5.4 a následne na Obrázok 5.5, v ktorom to čo sa javí ako okolitý šum je v skutočnosti jedno z mračien s veľkosťou násobne väčšou ako druhé mračno. Podobne sme teda aj vyrezali len tú časť surového mračna, ktorá spadala do porovnáwanej oblasti.



Obrázok 5.4 Dve mračná (zvýraznené žltou a červenou farbou) pred ICP



Obrázok 5.5 Nesprávne zarovnané mračná po ICP

Z histogramov Obrázok P. 5.17, Obrázok P. 5.18 a Obrázok P. 5.19 môžeme vidieť, že väčšie množstvo bodov patrí do oblasti desať percent najlepších vzdialeností. Výsledky sú v tomto ohľade výrazne lepšie ako v prípade predošlého datasetu, i keď pri metóde Meshroom ich stále pomerne značná časť do desaťpercentnej oblasti nepatrí.

Aj v tomto prípade má metóda Colmap najmenšiu hodnotu strednej vzdialenosti a štandardnej odchýlky ako môžeme vidieť v Tabuľka P. 1. Výsledok z tejto metódy môžeme označiť za vysoko podobný referenčnému mračnu čo sme mohli aj predpokladať, nakoľko tento dataset je stiahnutý z webových stránok Colmap. Mračno z metódy Meshroom sa opäť dá označiť za najslabšiu presnosť nakoľko má najvyššiu odchýlku spomedzi použitých metód. Aj pri tomto datasete je redšie avšak najmenšiu chybu má v tomto prípade Colmap. Naopak výsledok z MVSNet pri tomto datasete zaostáva za Colmap len kúsok, keďže má pomerne dobré hodnoty strednej vzdialenosti a štandardnej odchýlky, avšak maximálna vzdialenosť je násobne vyššia ako pri ostatných metódach, čo je spôsobené artefaktmi a šumom v mračne.

5.2.3 Porovnanie pre dataset 3


Dataset lebka má výrazne iné podmienky ako dataset socha a je to vidieť aj na hodnotách z porovnania, kde sa všetky metódy výrazne viac stabilizovali a výsledky sú značne presnejšie, čo zodpovedá predpokladu vyššej vhodnosti datasetu s kontrolovanými

podmienkami. Ak sa pozrieme na Obrázok 5.6, Obrázok 5.7 a Obrázok 5.8 vidíme, že prakticky všetky body spadajú do oblasti najbližších desať percent hodnôt vzdialeností, dokonca aj v rámci týchto desať percent sa približujú úplnému minimu.


Ako vidíme v Tabuľka 5.2, v tomto datasete už Colmap nedominovala a dokonca z hodnôt sa dá povedať, že bola spomedzi troch metód najhoršia, hoc to nie je celkom pravda. Výsledná rekonštrukcia má stále pri porovnaní výbornú strednú vzdialenosť aj štandardnú odchýlku. Maximálna vzdialenosť je však výrazne vyššia ako pri ostatných metódach, čo môžeme odôvodniť snahou zrekonštruovať aj objekty mimo centrálny objekt podobne ako to bolo pri predchádzajúcich datasetoch. Metóda Meshroom má výsledky s najlepšimi hodnotami a dalo by sa povedať, že rekonštrukcia je veľmi presná vzhľadom na referenčné mračno, avšak opäť treba mať na pamäti, že mračno z metódy Meshroom obsahovalo podstatne menej bodov a bolo redšie, ako mračná z ostatných metód a teda nemôžeme jednoznačne prehlásiť, že metóda je tu najpresnejšia. Výborné výsledky pri datasete lebka dosiahla metóda MVSNet, ktorá sa presnosťou rekonštrukcie veľmi približuje k referenčnému mračnu a jediným nedostatkom je opäť prítomnosť jemného šumu v mračne, ako môžeme vidieť na hodnote maximálnej vzdialenosti.

Tabuľka 5.2 Výsledky porovnania metód pre dataset lebka


Metódy	Stredná vzdialenosť [-]	Maximálna vzdialenosť [-]	Štandardná odchýlka [-]	σ [-]	Maximálna chyba [-]
Colmap	0,0044	1,3075	0,0187	0,0195	0,0129
Meshroom	0,0011	0,0711	0,0016	0,0017	0,0084
MVSNet	0,0012	0,5773	0,0023	0,0024	0,0085



Obrázok 5.6 Graf hodnôt vzdialenosti bodov Colmap, dataset lebka



Obrázok 5.7 Graf hodnôt vzdialenosti bodov Meshroom, dataset lebka



Obrázok 5.8 Graf hodnôt vzdialenosti bodov MVSNet, dataset lebka

5.2.4 Porovnanie pre dataset 4

Podobne ako dataset lebka aj dataset ulita vznikol pri kontrolovaných podmienkach a výsledné hodnoty porovnania môžeme interpretovať podobne v oboch prípadoch s malým zhoršením v datasete ulita. Na Obrázok P. , Obrázok P. a Obrázok P. vidíme, že drvivá väčšina bodov aj tu patrí do oblasti desať percent najbližších hodnôt vzdialenosti aj keď nie sú natoľko blízko minimu, ako v prípade predchádzajúceho datasetu. Toto je jednoznačne vidieť aj pri vizuálnej kontrole datasetov, kde oba majú výbornú podobnosť geometrie s rozdielom väčšieho množstva artefaktov v datasete ulita.

Ak sa pozrieme do Tabuľka P. 2 vidíme, že metóda Colmap má výsledky obdobné tým z datasetu lebka, je pomerne presná čo vidíme na nízkej hodnote strednej vzdialenosti a štandardnej odchýlky, avšak v mračne sa nachádzajú artefakty vzdialené od centrálného objektu, o čom vypovedá vyššia hodnota maximálnej vzdialenosti. Ako sme už spomínali nie je to obzvlášť prekvapujúce, keďže metóda sa pravdepodobne pokúša zrekonštruovať aj širšie okolie objektu. Výsledok z metódy Meshroom má opäť jednoznačne najlepšie hodnoty porovnávacích parametrov z čoho vyvodzujeme, že veľmi dobre kopíruje geometriu objektu a neobsahuje obzvlášť veľké množstvo artefaktov alebo šumu. Stále však platí, že zároveň nižší počet bodov (viď. Tabuľka 4.2) a hustota mračna majú skresľujúci vplyv na tieto porovnania a výsledná rekonštrukcia nie je jednoznačne najkvalitnejšia. Zaujímavé sú hodnoty porovnania výsledku z metódy MVSNet, ktoré sa


javia najhoršie z pomedzi použitých metód, avšak jednoznačným faktorom je prítomnosť rozsiahlejších mračien šumu v rekonštrukcii, ktorá má inak vysoký počet bodov a výbornú hustotu (viď. Tabuľka 4.3).

5.2.5 Porovnanie pre dataset 5

Dataset trs banánov je najmenší a bol využívaný na rýchle preverenia funkčnosti metód a do tohto porovnania slúži predovšetkým, ako ukážka schopnosti metód pracovať a vytvoriť výsledok aj s pomocou menšieho množstva vstupných dát. Pri pohľade na Obrázok P. , Obrázok P. a Obrázok P. je zrejmé, že aj pri tomto datasete sa body v mračnách z rekonštrukcií radia do oblasti desať percent najbližších vzdialeností. V prípade metódy Colmap a Meshroom ide o validný výsledok, ktorý skutočne vizuálne kopíruje geometriu rekonštruovaného objektu. Metóda MVSNet je problematická pre značnú neúplnosť, ktorá deformuje výsledky porovnania. Preto sme pre ukážku nedokonalosti tohto porovnania pridali aj spätné porovnanie v ktorom referenčné mračno bolo použité, ako porovnávané a výsledok z MVSNet ako referenčné.

Pre metódu Colmap je výsledok veľmi podobný referenčnému mračnu, podľa Tabuľka P. 3 sú hodnoty strednej vzdialenosti aj štandardnej odchýlky nízke a jav kedy maximálna vzdialenosť bola výrazne vyššia, ako pri ostatných metódach. Toto je spôsobené čiastočne regulovaný faktom, že okolie centrálného objektu je v značnej miere aj súčasťou referenčného mračna. Výsledok z metódy Meshroom je aj v tomto prípade na výborných hodnotách no podobne, ako doteraz aj tu nesmieme zabúdať na relatívne malé množstvo a hustotu bodov v mračne, i keď stále je jednoznačné o aký objekt ide a geometria je zachytená pomerne presne. Zaujímavé výsledky môžeme konštatovať pre metódu MVSNet, ktorá v pôvodnom porovnaní má hodnoty ktoré sa už značne približujú k výnimočne dobrej presnosti. Tento jav je predovšetkým spôsobený obrovskou nekompletnosťou mračna, a to až v takej miere, že je prakticky takmer nemožné identifikovať o aký objekt ide a geometria pôvodného objektu nie je zrejmá. Keďže príručka programu CloudCompare odporúča v porovnostiach využívať mračno s väčším počtom bodov, ako referenčné pri hľadaní párov bodov sa prejdú všetky body v porovnávanom mračne a hľadá sa k nim najbližší bod v referenčnom mračne. Toto spôsobuje, že pri takto nekompletnom mračne sa výsledky javia ako veľmi dobré a rekonštrukcia by sa mala považovať za presnú i keď realita je iná. Pre ukážku a korekciu sme preto v tomto prípade vykonali ešte druhé porovnanie, kde tentoraz ako referenčné mračno bude vystupovať nekompletné mračno z MVSNet a naše referenčné mračno bude

na mieste porovnávaného. Tým sme demonštrovali aké veľké sú nedokonalosti mračna z MVSNet, nakoľko chýbajú celé oblasti bodov. Jednoznačne to môžeme vidieť v grafe na Obrázok P. , kde sú body rozložené po celej škále možných hodnôt vzdialeností. Podobnú informáciu vidíme aj na Obrázok 5.9, kde modré body sú blízko a postupne k červenej sa vzdialenosť zväčšuje. Výsledné hodnoty v Tabuľka P. 3 sú pre toto spätné porovnanie rovnako výrazne horšie ako hodnoty ostatných porovnaní, čo potvrdzuje veľkú nedokonalosť mračna aj bez potreby vizuálnej kontroly.




Obrázok 5.9 Heat mapa porovnania neúplného mračna s referenčným


5.2.6 Porovnanie s MiDaS

Pre dosiahnutie aspoň približných hodnôt v metóde MiDaS sme zvolili obmenenú metodiku, kde sme do nástroja Cloud Compare namiesto spojených mračien, ktoré boli geometricky úplne nesprávne, vložili po jednom čiastkovom mračne z jednotlivých pohľadov pre každý dataset. Tieto čiastkové mračná kopírujú geometriu originálneho objektu aspoň v miere, kde pri pohľade pod patričným uhlom je rozlíšiteľné o aký objekt sa jedná. Vyberali sme čiastkové mračná z takých pohľadov, kde bola geometria zachytená najlepšie čo dávalo aspoň nejakú šancu na úspech porovnania. Ani tento postup sa však nepreukázal ako použiteľný, nakoľko už vo fáze zarovnania pomocou párov bodov bolo náročné vybrať také aby sa zarovnanie zlepšilo (viď. Obrázok 5.10) a následné presnejšie zarovnania pomocou algoritmu ICP zlyhávali a mračno transformovali na nesprávne veľkosti a otočenia rozdielne oproti s referenčnému mračnu,


ako vidíme na Obrázok 5.11 a Obrázok 5.12. Následné porovnanie sa vykonalo avšak pre nesprávne zarovnanie nedávalo zmysel (viď. Obrázok 5.13).




Obrázok 5.10 Zarovnanie pomocou 4 párov bodov



Obrázok 5.11 Pred zarovnaním cez algoritmus ICP



Obrázok 5.12 Poloha mračien po zarovnaní algoritmom ICP



Obrázok 5.13 Výsledok porovnania


5.2.7 Súhrnné porovnanie

Ak sa pozrieme na trendové krivky pre jednotlivé parametre porovnania mračien na Obrázok 5.14, Obrázok 5.15, Obrázok 5.16, Obrázok 5.17 a Obrázok 5.18, môžeme pozorovať klesajúci trend kriviek, čo zodpovedá faktu, že datasety socha a Gerrard Hall, ktoré majú vyššie hodnoty boli práve z exteriéru a nemali podmienky natoľko kontrolovaná ako ostatné, čím je pravdepodobnosť chýb a horších hodnôt značne vyššia.


Pri metrike stredná vzdialenosť sa celkovo javí ako najstabilnejší trend metódy Colmap, čo jednoznačne poukazuje na, dobrú presnosť v rámci všetkých scenárov. Podobne môžeme konštatovať pre Colmap aj trendy metriky štandardná odchýlka a sigma, ktoré majú nízky rozptyl a poukazujú na dobrú stabilitu metódy. Horšie to je pri metrike maximálnej vzdialenosti, na ktorej môžeme vidieť, že nie je najlepšia spomedzi metód a naznačuje, že metóda Colmap je náchylná na výskyt rozptýlených artefaktov vo väčších vzdialenostiach, avšak aj v tomto je metóda pomerne konštantná medzi jednotlivými datasetmi o čom svedčí aj trend maximálnej chyby.

Metóda Meshroom sa javí ako menej konzistentná naprieč rôznymi datasetmi o čom svedčia výraznejšie odskoky strednej vzdialenosti, štandardnej odchýlky a sigmy. Zlepšenie v hodnotení trendov tejto metódy predstavuje predovšetkým maximálna vzdialenosť a chyba, ktoré naznačujú vyššiu odolnosť metódy na výskyt artefaktov a šumu vo výslednom mračne.


Pri metóde MVSNet tiež vidíme výkyvy v hodnotách jednotlivých metrík, kde pri niektorých sú hodnoty strednej vzdialenosti, štandardnej odchýlky aj sigmy dobré no inokedy odskočia do výrazne horších. Metriky maximálnej vzdialenosti a maximálnej chyby zase jasne ukazujú, že podobne ako metóda Colmap aj metóda MVSNet je značne náchylná na výskyt extrémov – artefaktov vzdialených od centrálného objektu, podobne aj výskyt jemného šumu.




Obrázok 5.14 Trendová krivka pre strednú vzdialenosť




Obrázok 5.15 Trendová krivka pre štandardnú odchýlku



Obrázok 5.16 Trendová krivka pre sigma



Obrázok 5.17 Trendová krivka pre maximálnu vzdialenosť



Obrázok 5.18 Trendová krivka pre maximálnu chybu

5.2.8 Porovnanie zaťaženia zdrojov

Z pohľadu výkonu môžeme na základe hodnôt v Tabuľka 5.3, Tabuľka P. 4, Tabuľka P. 5, Tabuľka P. 6 a Tabuľka P. 7 konštatovať, že jednotlivé metódy sa pri všetkých datasetoch chovali veľmi podobne a samotné využitie zdrojov bolo úmerné veľkosti datasetov len s drobnými výkyvmi.

Metóda Colmap je v rámci rekonštrukcií všetkých datasetov pomerne vyvážená v pomere trvania a celkového zaťaženia na zdroje. Efektívne využíva počas celého behu prostriedky obzvlášť GPU, ktoré je vysoko využité počas takmer celej rekonštrukcie. Môžeme konštatovať, že je viditeľné, ako sa tvorcovia počas rokov práce na tvorbe tohto nástroja skutočne výrazne zamerali aj na jeho optimalizáciu.

Pri metóde Meshroom vidieť, že má dobré trvanie avšak je najnáročnejšia na procesor aj na VRAM, výsledné mračná sú však redšie, ako je aj vidieť v Tabuľka 4.1, Tabuľka 4.2, Tabuľka 4.3. Tento fakt ju robí pomerne vhodnou na rýchle vizualizácie datasetov, ak nepožadujeme obzvlášť veľké množstvo bodov, nakoľko výsledné mračná sú často redšie.

MiDaS dosahuje výborné rýchlosti aj na veľkých datasetoch, za ktoré vďačí práve efektívnemu odhadu hĺbkových máp. Finálna rekonštrukcia však nie je obzvlášť presná a práve preto, že nevykonáva natoľko komplexné úkony ako ostatné metódy, je prakticky

nemožné konštatovať, že táto rýchlosť má nejakú väčšiu váhu. Avšak ako bolo už v našej práci spomínané, táto metóda vo svojej podstate nepostačuje na komplexnú rekonštrukciu, no prípadné riešenie schopné kompenzovať jej nedostatky by mohlo vo veľkej miere ťažiť z týchto vysokých rýchlostí.

Metóda MVSNet sa vzhľadom na jej dlhé trvania pri všetkých rekonštrukciách javí ako neefektívna, ak by sme pozerali len na dáta o využití zdrojov. Priemerné využitie GPU je malé čo je priamym následkom toho, že celý beh procesu je dlhý a v mnohých momentoch je GPU aj dlhší úsek času nevyužitý zatiaľ čo v iných úsekoch bola jednotka GPU zaťažená na maximum. Dôležité je tiež konštatovať, že výsledkom tejto dlhšie trvajúcej rekonštrukcie sú mračná s výrazne vyšším počtom a hustotou bodov ako tomu je u ostatných metód.

Tabuľka 5.3 Spotreba zdrojov pri rekonštrukcii, dataset socha


Metóda	Čas [min]	CPU priemerné využitie [%]	GPU priemerné využitie [%]	RAM priemerné využitie [mb]	VRAM priemerné využitie [mb]
Colmap	49,97	17,64	81,81	27800,15	2835,38
Meshroom	28.28	57.75	11.42	27058.95	4369.07
MiDaS	10.18	24.74	4.91	30583.34	3255.18
MVSNet	106.16	20.58	1.71	27363.6	2056.83

5.2.9 Vizuálne hodnotenie výsledkov

Dôležitým aspektom pri hodnotení výsledkov jednotlivých metód je aj ich vizuálny stav. Prehliadaním mračna v zobrazovacom programe je možné vizuálne zhodnotiť, jeho kompletnosť a hustotu bodov, mieru zašumenia a prítomnosť artefaktov. Pri kontrole výsledných rekonštrukcií sa zameriavame na vlastnosti datasetov, ako komplexnosť tvaru a povrchu, typ osvetlenia a vlastnosti materiálu, tie sú presnejšie uvedené v diagramoch Obrázok 5.19, Obrázok P. , Obrázok P. , Obrázok P. a Obrázok P. .

Pre metódu Colmap sú zrekonštruované centrálné objekty pri všetkých datasetoch pomerne kompletne a väčšie diery sa objavujú len zriedkavo a to v častiach ktoré, nie sú zachytené na vstupných fotografiách. Metóda sa vyvíjala s prihliadnutím na rekonštrukcie budov, ulíc či celých mestských častí, čo sa výrazne ukazuje pri datasetoch socha

a Gerrard Hall, ktoré vznikli vo vonkajšom prostredí a obsahujú preto zábery širšieho okolia. Tento fakt napomáha pri rekonštrukcii nie príliš komplexných tvarov centrálnych objektov avšak cenou je, že sa v rekonštrukcii objavujú celé úseky artefaktov z okolia a mračná sú rozsiahlejšie než v ostatných metódach. Pre datasety z vnútorných, kontrolovaných podmienok, ako je dataset lebka a ulita sa potom tento jav prejavuje ako jemné šmuhy artefaktov v širšom okolí centrálného objektu. Metóda si hravo poradí aj s komplexnejšími tvarmi a štruktúrami na povrchu a má skôr problém s rekonštrukciou záberov sa jednoliatym povrchom, pri ktorom sa ťažšie hľadajú rovnaké body medzi zábermi. Metóda je pomerne citlivá na extrémne svetelné podmienky ako sú odlesky alebo príliš tmavé miesta. V takýchto prípadoch sa vo výslednom mračne v daných oblastiach nachádzajú diery. Umelé svetlo, ktoré sme schopný regulovať môže preto pri tvorbe fotografií napomáhať následnému lepšiemu výsledku rekonštrukcie.



Obrázok 5.19 Vlastnosti rekonštruovaného objektu, dataset socha

Metóda Meshroom sa v rámci všetkých datasetov vyznačovala pomerne riedkymi mračnami bodov, ktoré však veľmi dobre kopírovali geometriu rekonštruovaného objektu a neobsahovali obzvlášť veľké množstvá artefaktov v širšom okolí, skôr sa jednalo o jemný šum v blízkosti centrálného objektu. Nedostatky možno pozorovať pri komplexnejších tvaroch, ako boli napríklad predné časti datasetu lebka, kde metóda nedokázala zachytiť detaily a nechala značné diery vo výslednom mračne. Podobne ako v prípade Colmap aj metóda Meshroom je citlivá na svetelné podmienky, čo je v kombinácii so spomenutými nedostatkami detailov vo výsledných mračnách výrazne horšie ako u Colmap.

Pri metóde MiDaS je náročné zhodnotiť výsledky podobným spôsobom ako v ostatných prípadoch. Je pomerne jasné, že v rámci našej práce sme nemali možnosť ani prostriedky pretvoriť hĺbkové mapy na kompletné 3D rekonštrukcie. Samotné hĺbkové mapy vytvorené touto metódou vyzerajú dobre a je slušný predpoklad, že s využitím patričných dodatočných riešení by malo byť možné vytvárať aj kvalitné husté mračná bodov. Výsledky čiastkových mračien majú značné nedostatky a skutočný tvar geometrie, ktorú zachytávajú je obvykle viditeľný len pri pohľade kopírujúcom pohľad fotografie. Nedokážeme povedať, ktoré spomenuté parametre vstupných datasetov, ani s akou mierou vplyvu pôsobia na tvorbu výsledných mračien, no pri samotných hĺbkových mapách sa zdá, že mnohé nedostatky iných metód sú tu potlačené.

Metóda MVSNet využívajúca neurónové siete a hlboké učenie sa ukázala ako pomerne silný konkurent klasických metód. Vizualne sú výsledky často zašumené hustými zhlukmi bodov. V rámci celého okolia centrálného objektu, čo zakrýva časť detailov, avšak takéto body by po odfiltrovaní nemali byť problémom. Obzvlášť veľkou silou tejto metódy je množstvo a hustota bodov, ktoré vzniknú, čo síce nemusí byť vždy výhoda no mračno je možné filtrovať a prečistiť a dosiahnuť o poznanie lepšie výsledky. Metóda sa celkom dobre zachovala aj na transparentných a reflektívnych materiáloch, obzvlášť na datasete Gerrard Hall a lebka, kde sa v týchto oblastiach neobjavujú tak veľké nedostatky ako pri iných metódach. Svetelné podmienky sa tiež javia ako menší problém ako pri predchádzajúcich metódach, avšak stále ostávajú diery v príliš tmavých miestach. Najviac očividným nedostatkom pri vizuálnej kontrole rozhodne je problém s rekonštrukciou pri malom počte vstupných záberov. Na maličkom datasete trs banánov sa ostatné metódy dostali s kvalitou rekonštrukcie na celkom dobrú úroveň avšak MVSNet zjavne nebola schopná dostatočne zrekonštruovať s tak malým datasetom. Je

pomerne náročné identifikovať aký tvar mal rekonštruovaný objekt a to až v takej miere, že pri mnohých otočeniach by neznalý pozorovateľ pravdepodobne nedokázal ani identifikovať čo bolo objektom rekonštrukcie.

5.3 Diskusia

5.3.1 Interpretácia výsledkov

V rámci zadania práce bolo preskúmať a implementovať štyri metódy 3D rekonštrukcie a následne porovnať ich výsledky. Už po vyhotovení rekonštrukcií bolo pomerne zjavné, že výsledok z metódy MiDaS nebude vhodný a nebolo na ňom možné ani vykonať porovnania presnosti. Metóda napriek výborným rýchlostiam a dobrej kvalite hĺbkových máp nebola v tomto prevedení určená na kompletnú 3D rekonštrukciu, má však výborný potenciál na dosiahnutie lepších výsledkov za predpokladu, že sa postup doplní o vhodné algoritmy na využitie hĺbkových máp aj s limitmi ktoré majú. V súčasnej podobe ako príklad reálneho využitia môže byť implementácia s kamerovými systémami, kde sa tvoria riedke mračná zo záberov počas celého snímania.

Pre metódu Colmap môžeme skonštatovať výbornú úroveň kvality a značnú optimalizáciu, ktorú autori dosiahli. Výsledky tejto metódy sú pomerne presné aj bez dodatočného filtrovania a iného spracovania po dokončení rekonštrukcie. Softvér Colmap bol vytvorený so zreteľom na rekonštrukciu veľkých scén a toto sme mohli pozorovať aj pri rekonštrukcií vonkajších datasetov. Výsledné mračná bodov mali konštantne dobrú úplnosť a hustotu bodov, artefakty vznikajúce v širokom okolí sa dajú ľahko odstrániť. Samotná optimalizácia je dobre viditeľná na využití zdrojov, kde proces rekonštrukcie využíva GPU takmer naplno počas celého behu.

Meshroom sa javí ako najslabší z metód v porovnaní presnosti, kde napriek dosiahnutiu veľmi dobrých hodnôt parametrov je táto skutočnosť skreslená malým počtom a nízkou hustotou výsledných mračien z tejto metódy. Metóda je schopná pomerne presne kopírovať geometriu rekonštruovaného objektu no pri menších detailoch býva nepresná alebo nekompletná. Jednotlivé rekonštrukcie sú však pomerne rýchle a s predpokladom vyladenia procesu na špecifickú situáciu majú priestor na dosiahnutie lepších výsledkov ako pri univerzálnom použití.

Metóda MVSNet bola v mnohých ohľadoch často horšia v hodnotách porovnania, k čomu ale prispelo obrovské množstvo bodov s vysokou hustotou vo výsledných

mračnách. Tieto mračná obsahovali hustý šum v blízkosti rekonštruovaného objektu a pri správnom odfiltrovaní by výsledky mohli byť značne lepšie. Metóda dokázala zrekonštruovať pomerne presne geometriu a niektoré materiály dokonca aj lepšie ako ostatné metódy. Cenou za tak veľké mračná bodov je v prípade MVSNet predovšetkým dlhšie trvanie procesu rekonštrukcie. Metóda ma stále priestor na zlepšenie no už teraz ju možno považovať za vysoko kvalitný postup 3D rekonštrukcie.

Celkovo môžeme konštatovať, že výsledky klasických metód majú stále svoje výhody a nemôžeme ich pokladať za zastaralé. Nové metódy využívajúce neurónové siete už dosahujú pomerne uspokojivé výsledky, no stále je veľký priestor na zlepšenie a verím, že s dodatočným vývojom dosiahnu výborné výsledky v horizonte niekoľkých rokov.

Vďaka dobrej dostupnosti a neustále sa zlepšujúcim výsledkom majú v praktických aplikáciách tieto metódy okrem samotného akademického prostredia môžu byť užitočným nástrojom v oblasti architektúry a interiérového dizajnu na urýchlenie získania jednoduchého pracovného modelu pri vykonávaní vizualizácii. V oblasti virtuálnej a rozšírenej reality môžu byť metódy uplatnené na tvorbu celých priestorov a lokácii ale aj jednoduchších objektov. Softvéry ako Colmap dokážu rekonštruovať celé ulice a budovy, už či pre virtuálne prehliadky, archiváciu kultúrneho a prírodného dedičstva. V spojení s technológiami 3D tlače majú mnohé metódy 3D rekonštrukcie potenciálne využitie pre rýchlu tvorbu náhradných dielov, prototypovanie a rekonštruovanie aj do fyzickej podoby. Aj mnohé iné možnosti, v robotike, medicíne, doprave, strojárstve a mnohých ďalších odvetviach.

ZÁVER

Cieľom našej práce bolo naštudovať problematiku fotogrametrie s využitím hĺbkových máp. Analyzovať klasické aj moderné metódy realizácie 3D rekonštrukcie a vytvoriť pre každú skript na spracovanie datasetu. Výsledky z jednotlivých metód porovnať z hľadiska presnosti, výkonu a vizuálnej kvality. Následne vyhodnotiť vlastnosti metód vzhľadom na typ rekonštruovanej scény.

Podarilo sa nám nájsť kvalitné materiály zaoberajúce sa nami rozoberanou problematikou a po preštudovaní a pochopení kľúčových aspektov sme prešli k analýze samotných metód. Medzi klasické metódy sa radí program Colmap a knižnica OpenCV, ktoré využívajú algoritmizáciu na realizáciu 3D rekonštrukcie. Samotné OpenCV ako knižnica nepostačuje na realizovanie fotogrametrického postupu a preto sme zvolili softvér Meshroom ako alternatívu, ktorá túto knižnicu využíva. Modernejšie metódy, ktoré využívajú neurónové siete a hlboké učenie, použité v našej práci sú MVSNet a MiDaS. Pre aktuálnejšiu a lepšiu implementáciu sme ako zástupcu MVSNet vybrali konkrétnu verziu PatchmatchNet a pre metódu MiDaS sme sa pokúsili nájsť alebo dotvoriť spôsob, ako z vytvorených hĺbkových máp vytvoriť mračná bodov, nakoľko metóda samotná je zameraná len na odhad hĺbky.

Počas tvorby skriptov sme museli riešiť niekoľko problémov obzvlášť pri metóde Meshroom, ktorá sa v poskytnutom postupe využitia cez príkazový riadok neustále vracala k základným nastaveniam. Toto sme riešili čiastočným využitím dostupného GUI, v ktorom sme vytvorili vlastnú sekvenciu krokov, ktorú následne skript spúšťa. Problémy sa vyskytli aj pri snahe doplniť rekonštrukciu cez MiDaS na výstupné mračno. Podarilo sa nám nájsť repozitár, ktorý využíval hĺbkovú mapu z MiDaS na vytvorenie mračna z jednej snímky. Rozšírili sme tento postup pre jednotlivé snímky o spojenie do jedného mračna avšak to sa preukázalo ako neefektívne a po niekoľkých verziách sme konštatovali, že riešenie na tento problém je komplexnejšie, ako nám rozmedzie tejto práce umožňuje zrealizovať.

Ako pomocný nástroj sme nad rámec zadania práce vytvorili jednoduchú aplikáciu umožňujúcu spúšťanie jednotlivých metód komfortnejšie pre používateľa. Okrem toho aplikácia implementuje aj monitorovanie priebehu rekonštrukcií a zaznamenávanie využitia dostupných zdrojov, čo sme využili neskôr pri analýze.

Celkovo sme vykonali rekonštrukciu piatich datasetov pomocou štyroch metód na porovnanie a piatou metódou, ktorá sa dá považovať za vysokokvalitný štandard v oblasti fotogrametrie, na vytvorenie referenčného mračna. Surové mračná sme s referenčným porovnávali v programe CloudCompare na presnosť jednotlivých metód cez vzdialenosť medzi mračnami. Z výsledkov sme dokázali identifikovať, ako sa jednotlivé metódy pri rôznych scénach blížia presnosťou k referenčnému mračnu a pre metódy Colmap, Meshroom aj MVSNet konštatujeme dobrú presnosť s nedokonalosťami, ktoré je zväčša možné odstrániť dodatočným spracovaním. Výsledky metódy MiDaS žiaľ nebolo možné korektne porovnať tak aby boli výsledné hodnoty s výpovednou hodnotou.

V rámci porovnania výkonu jednotlivých metód sme popísali aké sú praktické postrehy vzhľadom na scenár, ktorý by potenciálny používateľ mohol realizovať. Pri klasických metódach je možné vidieť vysokú mieru optimalizácie získanú rokmi vývoja daných softvérov a nie je vhodné tieto metódy považovať za zastaralé v porovnaní s modernejšími metódami, nakoľko stále dosahujú porovnateľné a často aj lepšie výsledky. Pre moderné metódy využívajúce neurónové siete vidíme obrovský potenciál za predpokladu dodatočného vývoja. Už v súčasnom stave dokážu výsledkami konkurovať klasickým metódam a stále ostáva priestor na ich zlepšenie ako sme už spomínali obzvlášť pri metóde MiDaS, ktorá dosahovala výborné rýchlosti. Vzhľadom na typ scény v jednotlivých datasetoch usudzujeme, že správne podmienky majú vplyv obzvlášť na klasické metódy a novšie dokážu prípadné nedostatky čiastočne kompenzovať, avšak správne osvetlenie a vlastnosti rekonštruovaného objektu stále zohrávajú rolu na kvalite výslednej 3D rekonštrukcie.

Celkovo považujeme výsledky práce za úspech a považujeme ciele práce za splnené, s konštatovaním, možných nadväzujúcich riešení na problémy, na ktoré sme počas riešenia natrafili. Jednoduchý nástroj na spúšťanie jednotlivých metód, ktorý vznikol ako pomôcka pre túto prácu bude spolu s implementáciou dostupný vo verejnom repozitári na webe.

ZOZNAM POUŽITEJ LITERATÚRY

- [1] “Understanding Structure From Motion Algorithms | by Teresa Lobo | Medium.” Accessed: Nov. 29, 2025. [Online]. Available: <https://medium.com/@loboateresa/understanding-structure-from-motion-algorithms-fc034875fd0c>
 - [2] Y. Furukawa and C. Hernández, “Multi-view stereo: A tutorial,” *Foundations and Trends in Computer Graphics and Vision*, vol. 9, no. 1–2, pp. 1–148, Jun. 2015, doi: 10.1561/06000000052.
 - [3] S. M. Seitz, B. Curless, J. Diebel, D. Scharstein, and R. Szeliski, “A Comparison and Evaluation of Multi-View Stereo Reconstruction Algorithms”, Accessed: Nov. 29, 2025. [Online]. Available: <http://vision.middlebury.edu/mview>.
 - [4] M. Goesele, B. Curless, and S. M. Seitz, “Multi-View Stereo Revisited”.
 - [5] F. Wang *et al.*, “Learning-based Multi-View Stereo: A Survey”.
 - [6] “[Literature Review] Active Neural 3D Reconstruction with Colorized Surface Voxel-based View Selection.” Accessed: Dec. 11, 2025. [Online]. Available: <https://www.themoonlight.io/en/review/active-neural-3d-reconstruction-with-colorized-surface-voxel-based-view-selection>
 - [7] B. Mildenhall, P. P. Srinivasan, M. Tancik, J. T. Barron, R. Ramamoorthi, and R. Ng, “NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis.”
 - [8] B. Mildenhall, P. P. Srinivasan, M. Tancik, J. T. Barron, R. Ramamoorthi, and R. Ng, “NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis,” *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 12346 LNCS, pp. 405–421, Mar. 2020, doi: 10.1007/978-3-030-58452-8_24.
 - [9] B. Kerbl, G. Kopanas, T. Leimkuehler, and G. Drettakis, “3D Gaussian Splatting for Real-Time Radiance Field Rendering,” *ACM Trans. Graph.*, vol. 42, no. 4, Aug. 2023, doi: 10.1145/3592433.
 - [10] “Optimal Projection for 3D Gaussian Splatting.” Accessed: Dec. 11, 2025. [Online]. Available: <https://arxiv.org/html/2402.00752v2>
 - [11] “Adam - AI Powered CAD.” Accessed: Dec. 06, 2025. [Online]. Available: <https://adam.new/>
 - [12] “Photogrammetry with the free Colmap app – CGPress.” Accessed: Dec. 11, 2025. [Online]. Available:
-

<https://cgpress.org/archives/cgtutorials/photogrammetry-with-the-free-colmap-app>

- [13] “OpenCV documentation index.” Accessed: Dec. 07, 2025. [Online]. Available: <https://docs.opencv.org/>
 - [14] R. Ranftl, K. Lasinger, D. Hafner, K. Schindler, and V. Koltun, “Towards Robust Monocular Depth Estimation: Mixing Datasets for Zero-shot Cross-dataset Transfer,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 44, no. 3, pp. 1623–1637, Jul. 2019, doi: 10.1109/TPAMI.2020.3019967.
 - [15] Y. Yao, “MVSNet: Depth Inference for Unstructured Multi-view Stereo”.
 - [16] T. Luhmann, S. Robson, S. Kyle, and J. Boehm, “Close-Range Photogrammetry and 3D Imaging,” *Close-Range Photogrammetry and 3D Imaging*, Nov. 2013, doi: 10.1515/9783110302783/HTML.
 - [17] “Python OpenCV: Epipolar Geometry - GeeksforGeeks.” Accessed: Apr. 22, 2026. [Online]. Available: <https://www.geeksforgeeks.org/python/python-opencv-epipolar-geometry/>
 - [18] “Camera Calibration Parameters and Configuration on BasicAI.” Accessed: Apr. 22, 2026. [Online]. Available: <https://docs.basic.ai/docs/camera-intrinsic-extrinsic-and-distortion-in-camera-calibration>
 - [19] “Stanford University.” Accessed: Apr. 22, 2026. [Online]. Available: http://web.stanford.edu/class/cs231a/lectures/lecture6_stereo_systems.pdf
 - [20] “COLMAP - Datasets.” Accessed: Mar. 28, 2026. [Online]. Available: <https://demuc.de/colmap/datasets/index.html>
 - [21] “GitHub - alanscodelog/photogrammetry-test-sets: Free to use (CC-BY) images for testing photogrammetry software. · GitHub.” Accessed: Mar. 28, 2026. [Online]. Available: <https://github.com/AlansCodeLog/photogrammetry-test-sets>
 - [22] “GitHub - OpenDroneMap/ODMdata: Example data for OpenDroneMap: <https://OpenDroneMap.org> sourced from a variety of sources · GitHub.” Accessed: Mar. 28, 2026. [Online]. Available: <https://github.com/OpenDroneMap/ODMdata>
-

ZOZNAM POUŽITÝCH PROMPTOV

"Vies mi prosim vytvorit nejaku osnovu/bodovy obsah ako by som mohol spracovat nasledovnu diplomovu pracu: [text zadania]" , ChatGPT, verzia 11.11.2025, OpenAI, vytvorené 11.11. 2025, chat.openai.com.

"Najdi prosim nejaku odbornu literaturu, vedecke publikacie alebo clanky, ktore su dostupne online na temu hlbkove mapy a mohol by som ich citovat v zaverecnej praci" , ChatGPT, verzia 20.11.2025, OpenAI, vytvorené 20.11. 2025, chat.openai.com.

"prosim podobnu vedecku literaturu aj na temu sfm a mvs" , ChatGPT, verzia 20.11.2025, OpenAI, vytvorené 20.11. 2025, chat.openai.com.

"este mi pohladaj aj nieco k Nerf metodam rekonstrukcie" , ChatGPT, verzia 20.11.2025, OpenAI, vytvorené 20.11. 2025, chat.openai.com.

"podobnym sposobom ako sme pre tym definovali mi najdi aj literaturu k MiDaS a MVSNet" , ChatGPT, verzia 2.12.2025, OpenAI, vytvorené 2.12. 2025, chat.openai.com.

ČESTNÉ VYHLÁSENIE

Vyhlasujem, že som zadanú diplomovú prácu vypracoval samostatne, pod odborným vedením vedúceho diplomovej práce Štech Adam, Ing. PhD., a používal som len literatúru uvedenú v práci.

Vyhlasujem, že som pri vypracúvaní predloženej záverečnej práce využil(a) nástroje umelej inteligencie ChatGPT výhradne na účely generovania námetov na štruktúru práce a vyhľadávanie zdrojov.

Potvrdzujem, že výsledný text práce je mojim autorským dielom, za jeho odbornú náplň nesiem plnú zodpovednosť a žiadna časť práce nebola prevzatá z výstupu umelej inteligencie bez kritického zhodnotenia a riadneho citovania v súlade s etickými princípmi.

V Žiline dňa 27. apríla 2026


Michal Červenec, Bc.

PRÍLOHOVÁ ČASŤ


ZOZNAM PRÍLOH

Obrázok P. 5.1 Mračno z Colmap - dataset Gerrard Hall	II
Obrázok P. 5.2 Mračno z Colmap - dataset lebka	II
Obrázok P. 5.3 Mračno z Colmap - dataset ulita	III
Obrázok P. 5.4 Mračno z Colmap - dataset trs banánov.....	III
Obrázok P. 5.5 Mračno z Meshroom - dataset socha	IV
Obrázok P. 5.6 Mračno z Meshroom - dataset Gerrard Hall	IV
Obrázok P. 5.7 Mračno z Meshroom - dataset ulita	V
Obrázok P. 5.8 Mračno z Meshroom - dataset trs banánov	V
Obrázok P. 5.9 Mračno z PatchmatchNet - dataset socha	VI
Obrázok P. 5.10 Mračno z PatchmatchNet - dataset Gerrard Hall	VI
Obrázok P. 5.11 Mračno z PatchmatchNet - dataset lebka.....	VII
Obrázok P. 5.12 Mračno z PatchmatchNet - dataset ulita	VII
Obrázok P. 5.13 Mračno z jedného obrázka z MiDaS - dataset socha	VIII
Obrázok P. 5.14 Mračno z jedného obrázka z MiDaS - dataset Gerrard Hall.....	VIII
Obrázok P. 5.15 Mračno z jedného obrázka z MiDaS - dataset lebka	IX
Obrázok P. 5.16 Mračno z jedného obrázka z MiDaS - dataset trs banánov.....	IX
Obrázok P. 5.17 Graf hodnôt vzdialenosti bodov Colmap, dataset Gerrard Hall, na osi X hodnoty vzdialenosti od 0 do 1, na osi Y počty bodov rádovo v 10^5	X
Obrázok P. 5.18 Graf hodnôt vzdialenosti bodov Meshroom, dataset Gerrard Hall, na osi X hodnoty vzdialenosti od 0 do 1, na osi Y počty bodov rádovo v 10^5	XI
Obrázok P. 5.19 Graf hodnôt vzdialenosti bodov MVSNet, dataset Gerrard Hall, na osi X hodnoty vzdialenosti od 0 do 1, na osi Y počty bodov rádovo v 10^5	XI
Obrázok P. 5.20 Graf hodnôt vzdialenosti bodov Colmap, dataset ulita.....	XII
Obrázok P. 5.21 Graf hodnôt vzdialenosti bodov Meshroom, dataset ulita	XII
Obrázok P. 5.22 Graf hodnôt vzdialenosti bodov MVSNet, dataset ulita	XIII
Obrázok P. 5.23 Graf hodnôt vzdialenosti bodov Colmap, dataset trs banánov	XIV
Obrázok P. 5.24 Graf hodnôt vzdialenosti bodov Meshroom, dataset trs banánov.....	XIV
Obrázok P. 5.25 Graf hodnôt vzdialenosti bodov MVSNet, dataset trs banánov.....	XV
Obrázok P. 5.26 Graf hodnôt vzdialenosti bodov MVSNet opačné porovnanie, dataset trs banánov	XV
Obrázok P. 5.27 Vlastnosti rekonštruovaného objektu, dataset Gerrard Hall	XVIII
Obrázok P. 5.28 Vlastnosti rekonštruovaného objektu, dataset lebka.....	XIX
Obrázok P. 5.29 Vlastnosti rekonštruovaného objektu, dataset ulita	XX
Obrázok P. 5.30 Vlastnosti rekonštruovaného objektu, dataset trs banánov	XXI
Obrázok P. 5.31 QR kód s linkom na repozitár	XXI
Tabuľka P. 1 Výsledky porovnania metód pre dataset Gerrard Hall	X
Tabuľka P. 2 Výsledky porovnania metód pre dataset ulita	XII
Tabuľka P. 3 Výsledky porovnania metód pre dataset trs banánov.....	XIII
Tabuľka P. 4 Spotreba zdrojov pri rekonštrukcii, dataset Gerrard Hall	XVI
Tabuľka P. 5 Spotreba zdrojov pri rekonštrukcii, dataset ulita	XVI
Tabuľka P. 6 Spotreba zdrojov pri rekonštrukcii, dataset lebka.....	XVI
Tabuľka P. 7 Spotreba zdrojov pri rekonštrukcii, dataset trs banánov	XVII


PRÍLOHA A | VÝSLEDNÉ MRAČNÁ Z JEDNOTLIVÝCH METÓD 3D REKONŠTRUKCIE




Obrázok P. 5.1 Mračno z Colmap - dataset Gerrard Hall



Obrázok P. 5.2 Mračno z Colmap - dataset lebka



Obrázok P. 5.3 Mračno z Colmap - dataset ulita



Obrázok P. 5.4 Mračno z Colmap - dataset trs banánov




Obrázok P. 5.5 Mračno z Meshroom - dataset socha



Obrázok P. 5.6 Mračno z Meshroom - dataset Gerrard Hall



Obrázok P. 5.7 Mračno z Meshroom - dataset ulita




Obrázok P. 5.8 Mračno z Meshroom - dataset trs banánov



Obrázok P. 5.9 Mračno z PatchmatchNet - dataset socha



Obrázok P. 5.10 Mračno z PatchmatchNet - dataset Gerrard Hall




Obrázok P. 5.11 Mračno z PatchmatchNet - dataset lebka



Obrázok P. 5.12 Mračno z PatchmatchNet - dataset ulita




Obrázok P. 5.13 Mračno z jedného obrázka z MiDaS - dataset socha



Obrázok P. 5.14 Mračno z jedného obrázka z MiDaS - dataset Gerrard Hall



Obrázok P. 5.15 Mračno z jedného obrázka z MiDaS - dataset lebka



Obrázok P. 5.16 Mračno z jedného obrázka z MiDaS - dataset trs banánov


PRÍLOHA B | POROVNANIA MRAČIEN Z JEDNOTLIVÝCH METÓD 3D REKONŠTRUKCIE VOČI REFERENČNÉMU MRAČNU

Tabuľka P. 1 Výsledky porovnania metód pre datased Gerrard Hall


Metódy	Stredná vzdialenosť [-]	Maximálna vzdialenosť [-]	Štandardná odchýlka [-]	σ [-]	Maximálna chyba [-]
Colmap	0,013	3,579	0,0334	0,032	0,1247
Meshroom	0,175	4,6755	0,2	0,4443	0,1368
MVSNet	0,0533	18,935	0,0596	0,2257	0,2023



Obrázok P. 5.17 Graf hodnôt vzdialenosti bodov Colmap, dataset Gerrard Hall, na osi X hodnoty vzdialenosti od 0 do 1, na osi Y počty bodov rádovo v 10⁵




Obrázok P. 5.18 Graf hodnôt vzdialenosti bodov Meshroom, dataset Gerrard Hall, na osi X hodnoty vzdialenosti od 0 do 1, na osi Y počty bodov rádovo v 10^5




Obrázok P. 5.19 Graf hodnôt vzdialenosti bodov MVSNet, dataset Gerrard Hall, na osi X hodnoty vzdialenosti od 0 do 1, na osi Y počty bodov rádovo v 10^5

Tabuľka P. 2 Výsledky porovnania metód pre dataset ulita


Metódy	Stredná vzdialenosť [-]	Maximálna vzdialenosť [-]	Štandardná odchýlka [-]	σ [-]	Maximálna chyba [-]
Colmap	0,0066	4,7043	0,0217	0,0317	0,0276
Meshroom	0,0042	1,3133	0,0215	0,0216	0,0185
MVSNet	0,0096	1,7443	0,0459	0,0483	0,019



Obrázok P. 5.20 Graf hodnôt vzdialenosti bodov Colmap, dataset ulita




Obrázok P. 5.21 Graf hodnôt vzdialenosti bodov Meshroom, dataset ulita




Obrázok P. 5.22 Graf hodnôt vzdialenosti bodov MVSNet, dataset ulita

Tabuľka P. 3 Výsledky porovnania metód pre dataset trs banánov


Metódy	Stredná vzdialenosť [-]	Maximálna vzdialenosť [-]	Štandardná odchýlka [-]	σ [-]	Maximálna chyba [-]
Colmap	0,0062	0,6452	0,0134	0,0134	0,0153
Meshroom	0,0039	0,2153	0,0065	0,007	0,0137
MVSNet	0,0027	0,3022	0,0045	0,005	0,014
MVSNet (spätné porovnanie)	0,251	1,35	0,2751	0,2838	0,0184




Obrázok P. 5.23 Graf hodnôt vzdialenosti bodov Colmap, dataset trs banánov



Obrázok P. 5.24 Graf hodnôt vzdialenosti bodov Meshroom, dataset trs banánov



Obrázok P. 5.25 Graf hodnôt vzdialenosti bodov MVSNet, dataset trs banánov



Obrázok P. 5.26 Graf hodnôt vzdialenosti bodov MVSNet opačné porovnanie, dataset trs banánov

PRÍLOHA C | POROVNANIA VÝKONU A ZAŤAŽENIA ZDROJOV

Tabuľka P. 4 Spotreba zdrojov pri rekonštrukcii, dataset Gerrard Hall

Metóda	Čas [min]	CPU priemerné využitie [%]	GPU priemerné využitie [%]	RAM priemerné využitie [mb]	VRAM priemerné využitie [mb]
Colmap	47.67	65.89	80.79	27054.94	2794.25
Meshroom	43.98	62.34	8.33	28963.96	3878.32
MiDaS	9.1	33.12	5.34	28388.9	3236.92
MVSNet	113.44	25.2	1.39	27816.69	2126.11

Tabuľka P. 5 Spotreba zdrojov pri rekonštrukcii, dataset ulita

Metóda	Čas [min]	CPU priemerné využitie [%]	GPU priemerné využitie [%]	RAM priemerné využitie [mb]	VRAM priemerné využitie [mb]
Colmap	46,49	18.91	81.78	27659.07	4116.51
Meshroom	23,55	63.06	9.11	27914.61	5067.17
MiDaS	3,36	32.34	9.75	26736.24	3733.42
MVSNet	81,91	21.23	1.94	27610.69	3192.43


Tabuľka P. 6 Spotreba zdrojov pri rekonštrukcii, dataset lebka

Metóda	Čas [min]	CPU priemerné využitie [%]	GPU priemerné využitie [%]	RAM priemerné využitie [mb]	VRAM priemerné využitie [mb]
Colmap	32.3	14.78	81.82	23466.74	4750.15
Meshroom	9.21	69.09	9.1	22809.16	5965.3
MiDaS	2,89	19.04	4.83	10847.25	2575.77
MVSNet	31,66	18.63	2.83	10571.77	1386.96


Tabuľka P. 7 Spotreba zdrojov pri rekonštrukcii, dataset trs banánov

Metóda	Čas [min]	CPU priemerné využitie [%]	GPU priemerné využitie [%]	RAM priemerné využitie [mb]	VRAM priemerné využitie [mb]
Colmap	6,87	19.74	77.69	26274.15	2271.79
Meshroom	2,23	49.49	5.86	25253.97	2442.20
MiDaS	0,61	21.24	2.89	25239.43	2327.24
MVSNet	2,22	32.47	6.92	25111.80	3946.96


PRÍLOHA D | VIZUÁLNE ZHODNOTENIE KVALITY PRE JEDNOTLIVÉ DATASETY




Obrázok P. 5.27 Vlastnosti rekonštruovaného objektu, dataset Gerrard Hall



Obrázok P. 5.28 Vlastnosti rekonštruovaného objektu, dataset lebka



Obrázok P. 5.29 Vlastnosti rekonštruovaného objektu, dataset ulita



Obrázok P. 5.30 Vlastnosti rekonštruovaného objektu, dataset trs banánov

PRÍLOHA E | LINK NA REPOZITÁR S VÝSLEDKAMI PRÁCE

<https://github.com/OnePCtoRuleThemAll/3DreconstructionApp.git>



Obrázok P. 5.31 QR kód s linkom na repozitár